INSTITUTO FEDERAL
Goiás

Deep Learning

Prof. Sérgio Canuto - sergio.canuto@ifg.edu.br

Autoinscrição - Moodle

https://moodle.ifg.edu.br/course/view.php?id=59560

Senha: dl20262

Sobre o professor…

INSTITUTO FEDERAL
Goiás

- Graduação
  - INF/UFG - Ciência da Computação - 2009
- Mestrado
  - INF/UFG - “Um estudo comparativo entre abordagens supervisionadas para resolução de referências a autores” - 2011
- Doutorado
  - UFMG - “A Thorough Exploitation of Distance-Based Meta-Features for Automated Text Classification” - 2019 (Vencedora CTDBD)

- Professor de:
  - *Estrutura de dados, Projeto avançado de algoritmos, Mineração de dados, Deep Learning, Processamento de Linguagem Natural.*

- Projetos:
  - Classificação de documentos, extração de informações de texto, redes sociais, NL2SQL, petrobrás, telemarketing…

http://lattes.cnpq.br/5172447060300953

Sobre os alunos…

- Que experiências você já teve ou pretende ter com a IA?
- Partindo de suas experiências…
  - Qual a primeira conceituação que vem à mente com o termo “*deep learning*”?

Sobre os alunos…

INSTITUTO FEDERAL
Goiás

- Que experiências você já teve ou pretende ter com a IA?
- Partindo de suas experiências…
  - Qual a primeira conceituação que vem à mente com o termo “*deep learning*”?
  - Porque o *deep learning* está tão em voga ultimamente?

Sobre os alunos…

INSTITUTO FEDERAL
Goiás

- Que experiências você já teve ou pretende ter com a IA?
- Partindo de suas experiências…
  - Qual a primeira conceituação que vem à mente com o termo “*deep learning*”?
  - Porque o *deep learning* está tão em voga ultimamente?
  - Você já conhece alguma aplicação de *deep learning*?
    - … ou alguma técnica de *deep learning*?

Sobre os alunos…

INSTITUTO FEDERAL
Goiás

- Que experiências você já teve ou pretende ter com a IA?
- Partindo de suas experiências…
  - Qual a primeira conceituação que vem à mente com o termo “*deep learning*”?
  - Porque o *deep learning* está tão em voga ultimamente?
  - Você já conhece alguma aplicação de *deep learning*?
    - … ou alguma técnica de *deep learning*?
  - Qual a relação entre *deep learning* e as outras técnicas de aprendizado de máquina?
    - … o que tem de similar?
    - … e o que tem de diferente?

Sobre os alunos…

INSTITUTO FEDERAL
Goiás

- Que experiências você já teve ou pretende ter com a IA?
- Partindo de suas experiências…
  - Qual a primeira conceituação que vem à mente com o termo “*deep learning*”?
  - Porque o *deep learning* está tão em voga ultimamente?
  - Você já conhece alguma aplicação de *deep learning*?
    - … ou alguma técnica de *deep learning*?
  - Qual a relação entre *deep learning* e as outras técnicas de aprendizado de máquina?
    - … o que tem de similar?
    - … e o que tem de diferente?
  - O que é necessário para aplicar *deep learning* na prática?

Deep Learning:
Contextualização, motivação e definições.

O que é Deep Learning?

Inteligência Artificial

Técnicas que permitem o computador "imitar" o comportamento humano.

"pensam" como humanos/
"pensam" racionalmente/
"agem" como humanos/
"agem" racionalmente.
(Norvig, 1995)

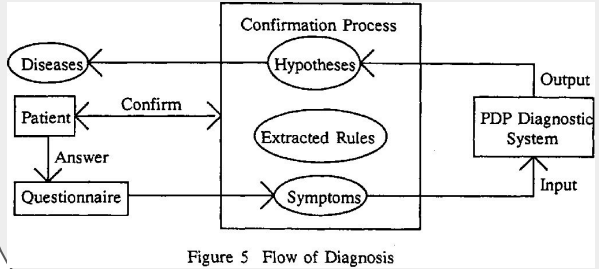
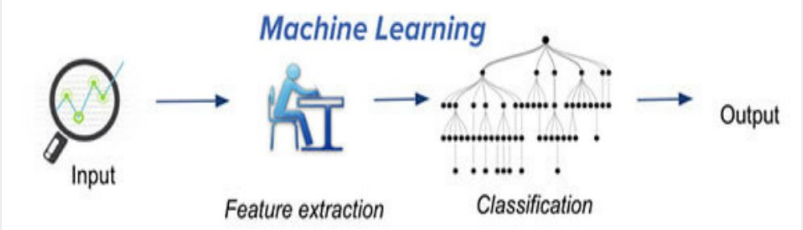


Figure 5 Flow of Diagnosis

Aprendizado de Máquina

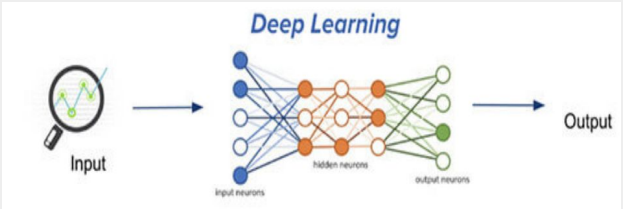
Habilidade de aprender sem programação explícita.

Aqui, Inteligência é a capacidade de aprender padrões a partir de dados e usar esse aprendizado para tomar boas decisões ou fazer previsões em situações novas.



Aprendizado Profundo

Extrai padrões dos dados usualmente com redes neurais.



O que é Deep Learning?

INSTITUTO FEDERAL
Goiás

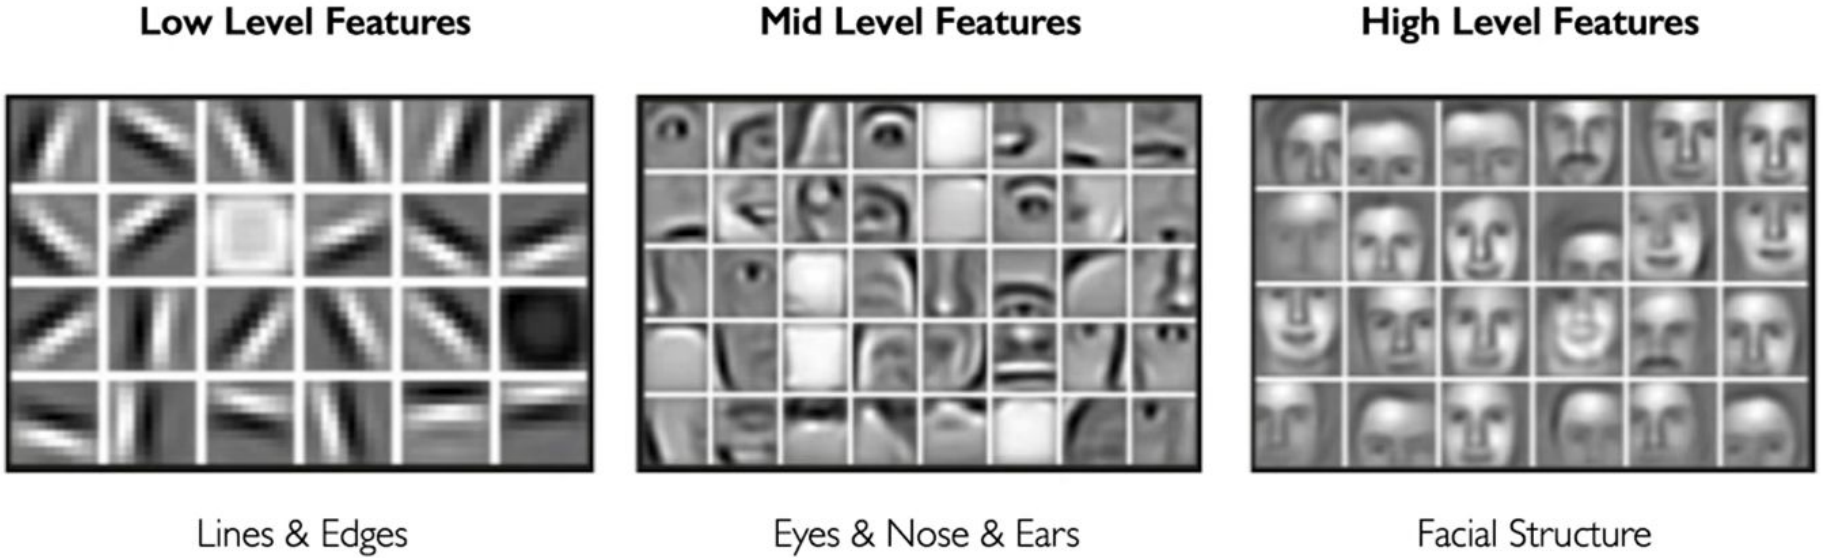
- (..) a solution to allow computers to learn from experience and understand the world in terms of a hierarchy of concepts, with each concept defined through its relation to simpler concepts. By gathering knowledge from experience, this approach avoids the need for human operators to formally specify all the knowledge that the computer needs. The hierarchy of concepts enables the computer to learn complicated concepts by building them out of simpler ones.
- If we draw a graph showing how these concepts are built on top of each other, the graph is deep, with many layers. For this reason, we call this approach to AI deep learning.



Ian J. Goodfellow, Yoshua Bengio and Aaron Courville. **Deep Learning**, MIT Press, 2016.

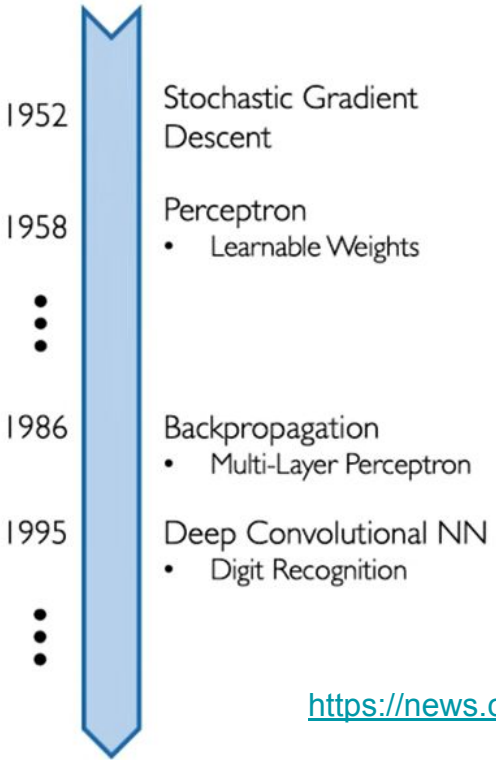
O que é Deep Learning?

INSTITUTO FEDERAL
Goiás



Ian J. Goodfellow, Yoshua Bengio and Aaron Courville. **Deep Learning**, MIT Press, 2016.

Porque Agora?

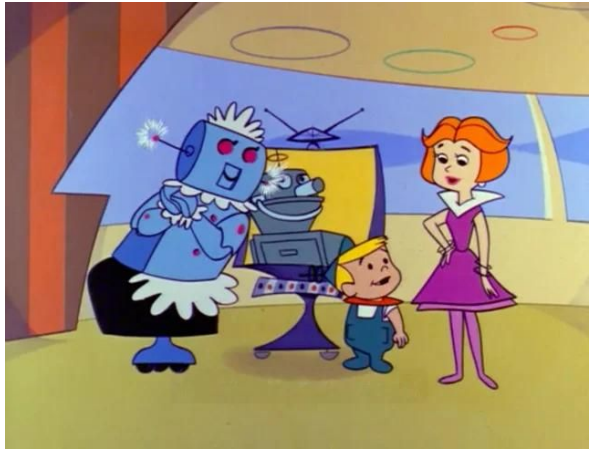


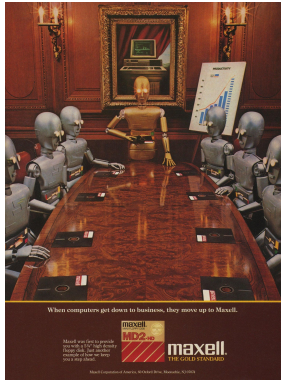
Percalços

- 1969: Crítica dos neurônios perceptron.
- 1971–75: cortes governamentais (DARPA) devido ao fracasso na tradução automática e IA em geral.
- 1973: Lighthill report (Inglaterra): falha da IA em atingir objetivos "grandiosos" devido ao alto custo computacional… explosão combinatória de fatores em aplicações reais.
- 1990s: Soluções de machine learning se apresentaram efetivas e com baixo custo computacional

https://news.cornell.edu/stories/2019/09/professors-perceptron-paved-way-ai-60-years-too-soon

Percalços…







Período	Inverno da IA	Principais causas
1956–1973	**Pré-inverno**	**GRANDE OTIMISTMO COM IA**
1974–1980	**1º Inverno da IA**	• Expectativas exageradas; • pouco poder computacional; • limitações dos primeiros sistemas de IA; • dificuldades dos perceptrons; • resultados fracos em tradução automática; • relatório Lighthill (1973) e redução de financiamento.
1980–1987	**Pré-inverno**	**GRANDE OTIMISTMO COM IA**
1987–1994	**2º Inverno da IA**	• Sistemas especialistas caros, frágeis e difíceis de manter; • colapso do mercado de máquinas Lisp; • expectativas não cumpridas em projetos; • alternativas computacionais convencionais mais baratas.

Porque Agora?

INSTITUTO FEDERAL
Goiás

1952 Stochastic Gradient Descent

1958 Perceptron
- Learnable Weights

1986 Backpropagation
- Multi-Layer Perceptron

1995 Deep Convolutional NN
- Digit Recognition

Neural Networks date back decades, so why the resurgence?

1. Big Data
- Larger Datasets
- Easier Collection & Storage

IMAGENET

WIKIPEDIA
The Free Encyclopedia



2. Hardware
- Graphics Processing Units (GPUs)
- Massively Parallelizable



3. Software
- Improved Techniques
- New Models
- Toolboxes

TensorFlow

Porque Agora?

- Paradigma conexionista foi viabilizado pelo crescimento absurdo do poder computacional.

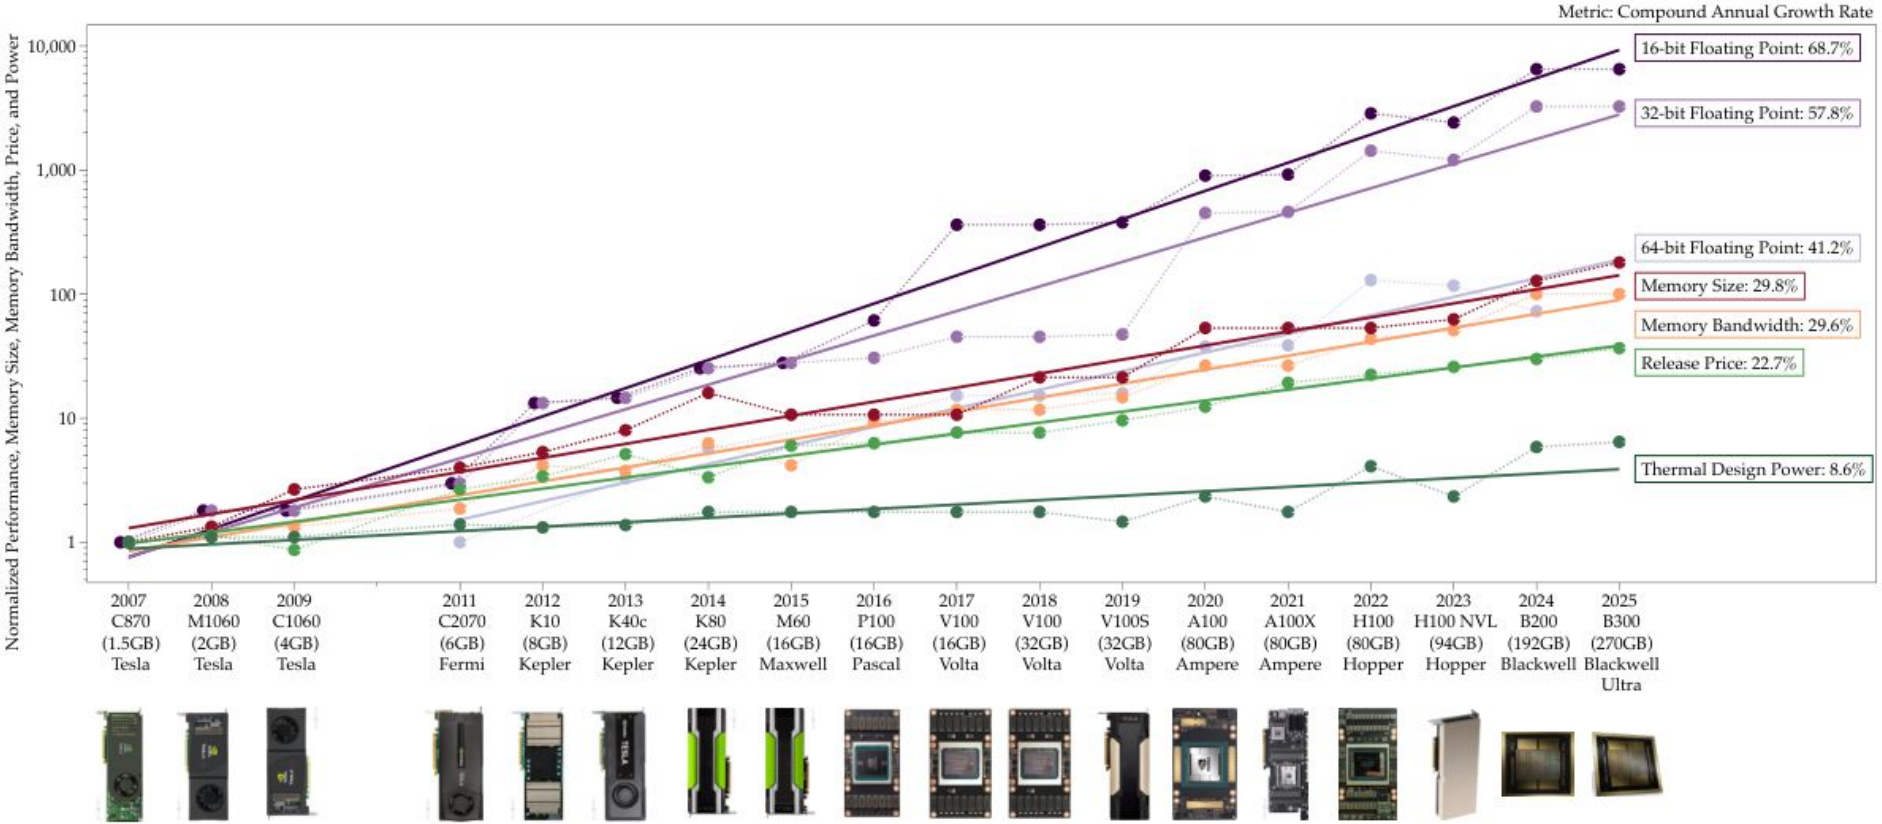
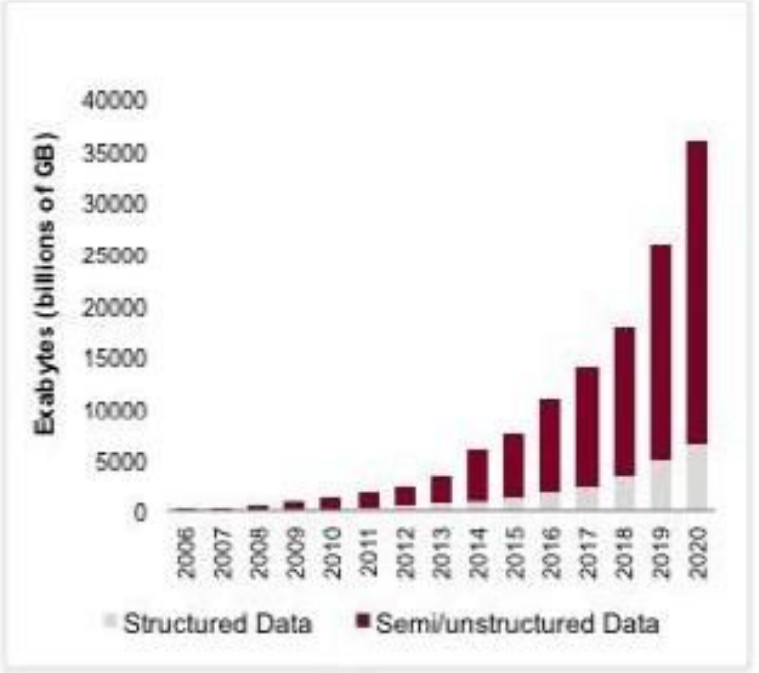


Image sources: ahead-it.eu, epoch.ai, nvidia.com, techpowerup.com, videocardz.net
Price sources: lambdalabs.com, microway.com, northflank.com, shi.com, techpowerup.com, videocardz.net

Porque Agora?

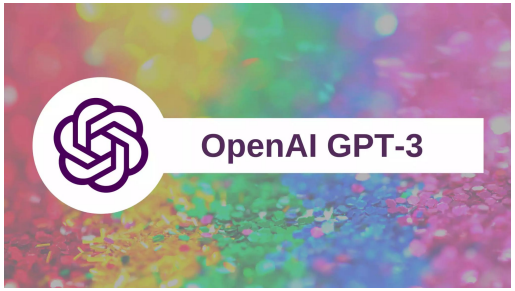
- Paradigma conexionista foi viabilizado com:
  - Crescimento absurdo do poder computacional.
  - Crescimento absurdo de dados disponíveis.



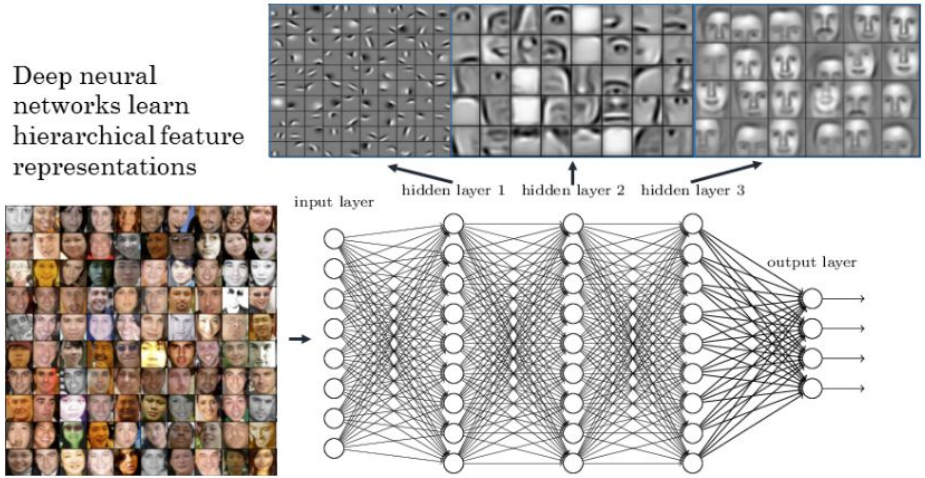
Fonte: Big Data Analysis and Storage

Porque Agora?

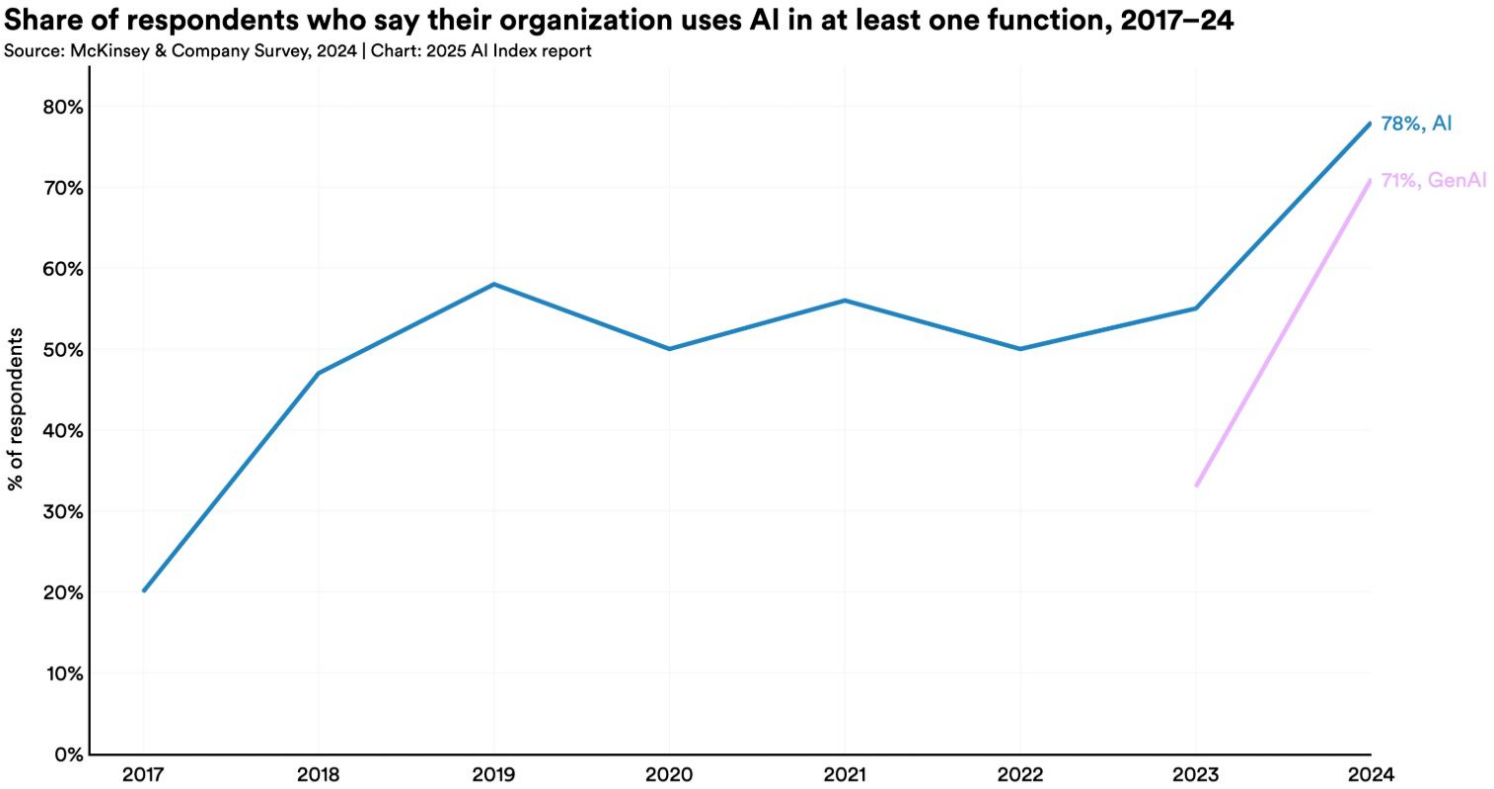
- Paradigma conexionista foi viabilizado com:
  - Crescimento absurdo do poder computacional.
  - Crescimento absurdo de dados disponíveis.
  - Novas formas para organizar/tratar os neurônios artificiais.







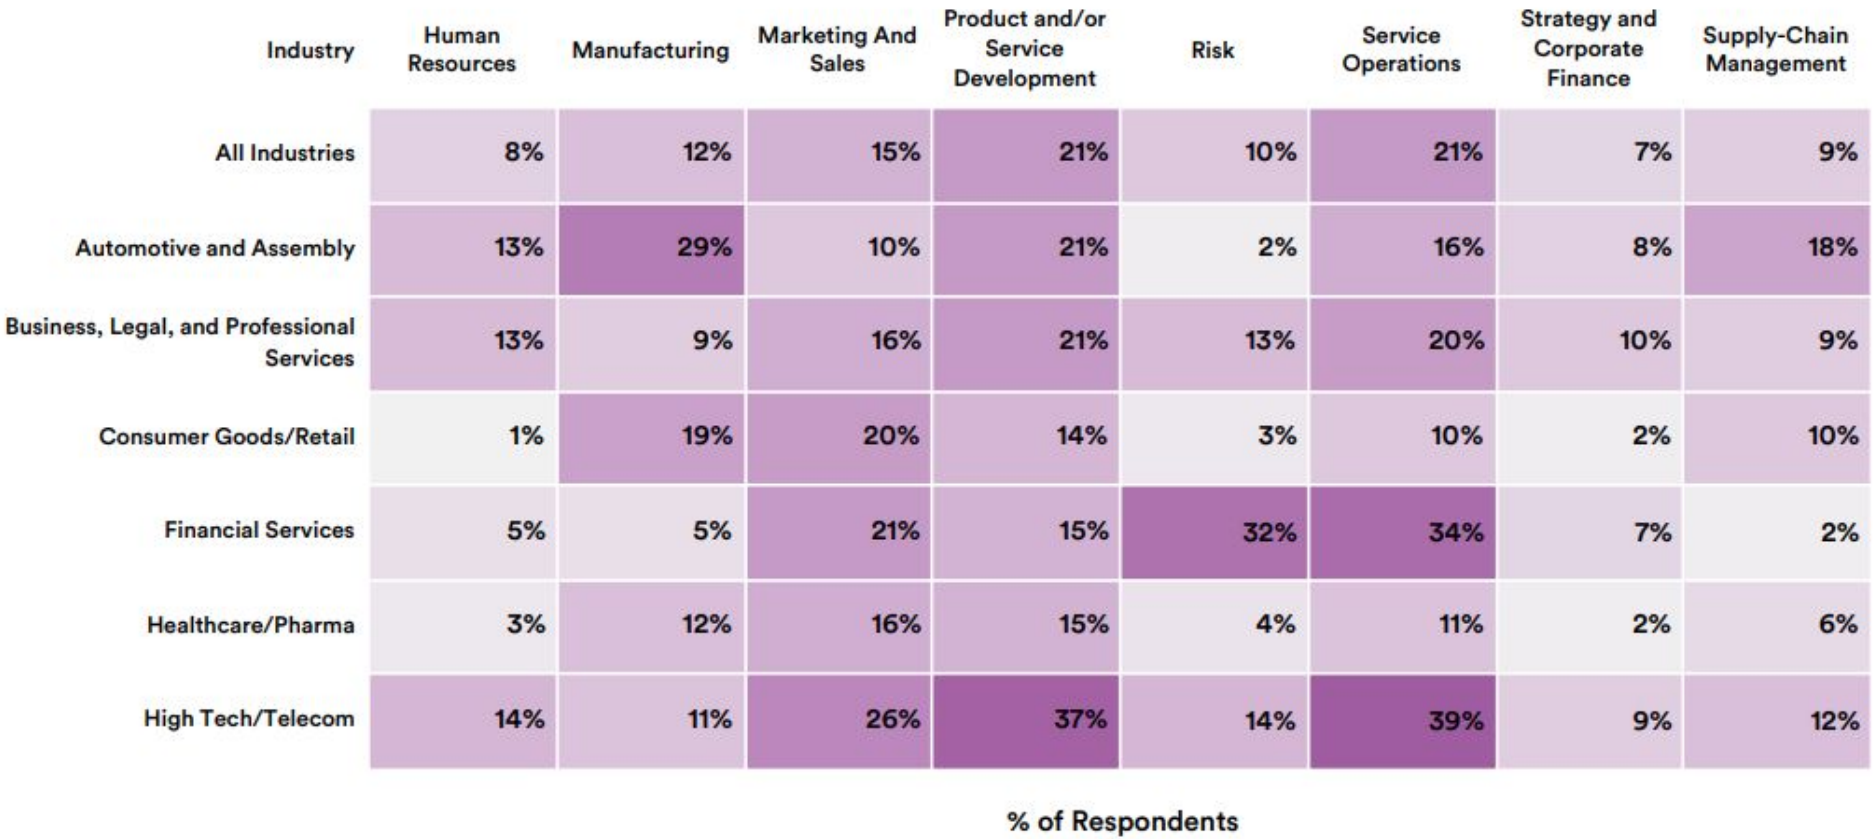
Consequência: Organizações usam IA/deep learning



Fonte: "Artificial Intelligence Index" https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf

AI ADOPTION by INDUSTRY & FUNCTION, 2020

Source: McKinsey & Company, 2020 | Chart: 2021 AI Index Report

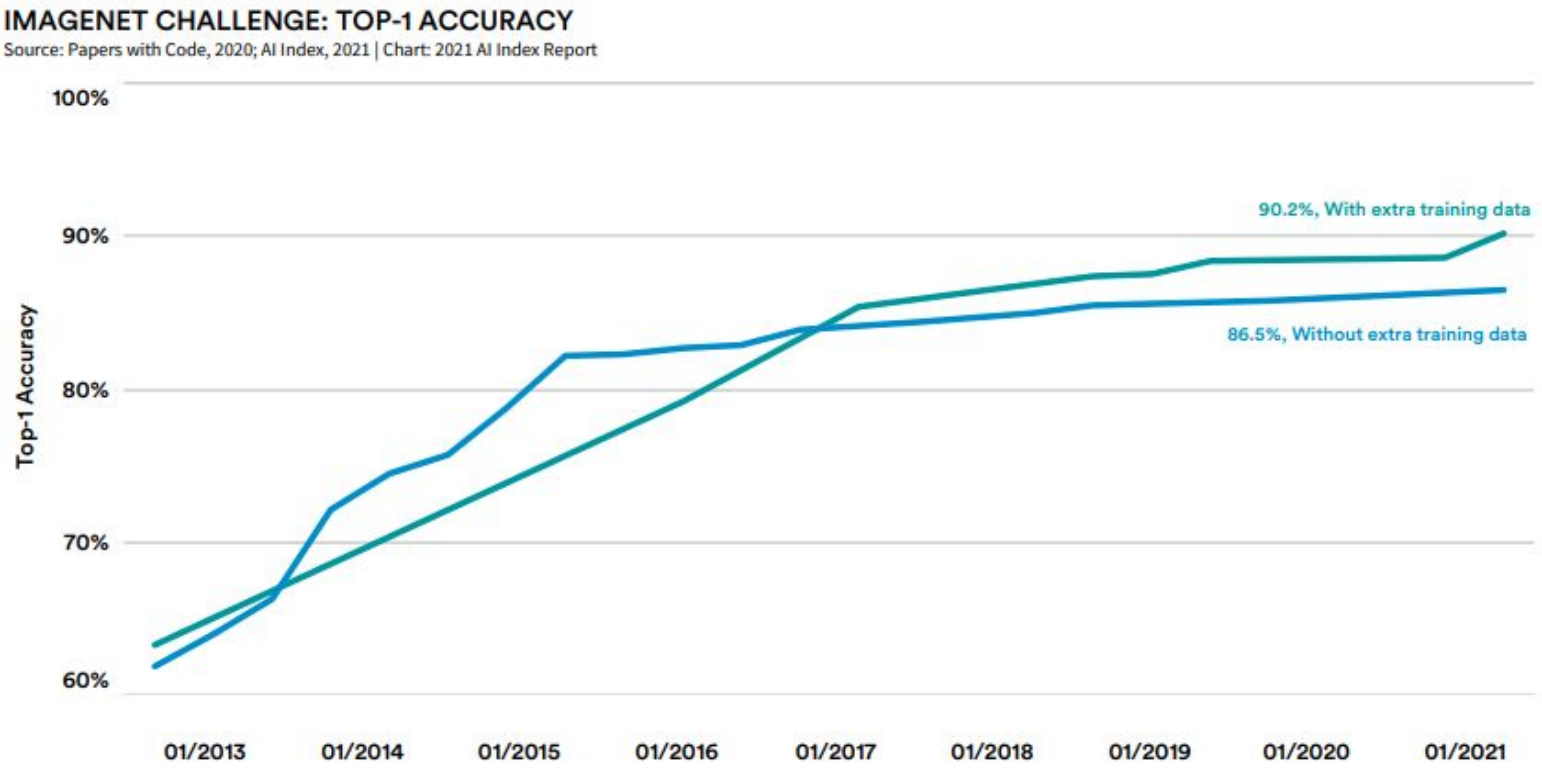


Industry	Human Resources	Manufacturing	Marketing And Sales	Product and/or Service Development	Risk	Service Operations	Strategy and Corporate Finance	Supply-Chain Management
All Industries	8%	12%	15%	21%	10%	21%	7%	9%
Automotive and Assembly	13%	29%	10%	21%	2%	16%	8%	18%
Business, Legal, and Professional Services	13%	9%	16%	21%	13%	20%	10%	9%
Consumer Goods/Retail	1%	19%	20%	14%	3%	10%	2%	10%
Financial Services	5%	5%	21%	15%	32%	34%	7%	2%
Healthcare/Pharma	3%	12%	16%	15%	4%	11%	2%	6%
High Tech/Telecom	14%	11%	26%	37%	14%	39%	9%	12%

% of Respondents

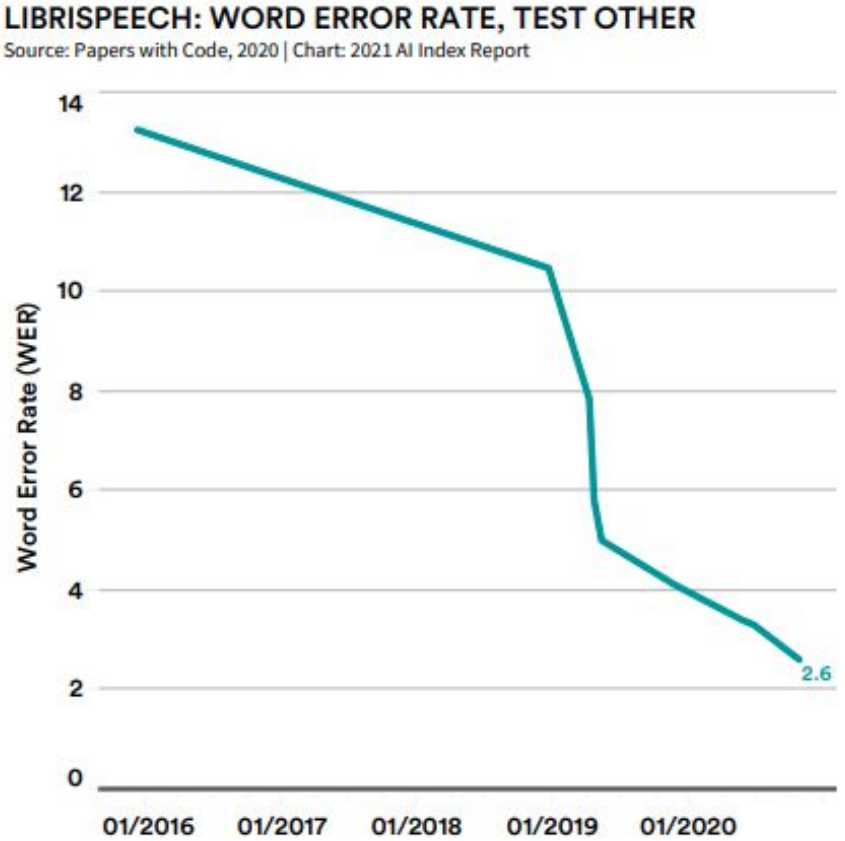
Fonte: https://aiindex.stanford.edu/wp-content/uploads/2021/03/2021-AI-Index-Report-_Chapter-3.pdf

Consequência: Emprego da IA em Classificação de Imagens



https://aiindex.stanford.edu/wp-content/uploads/2021/03/2021-AI-Index-Report-_Chapter-2.pdf

Consequência: Emprego da IA em Reconhecimento de Fala



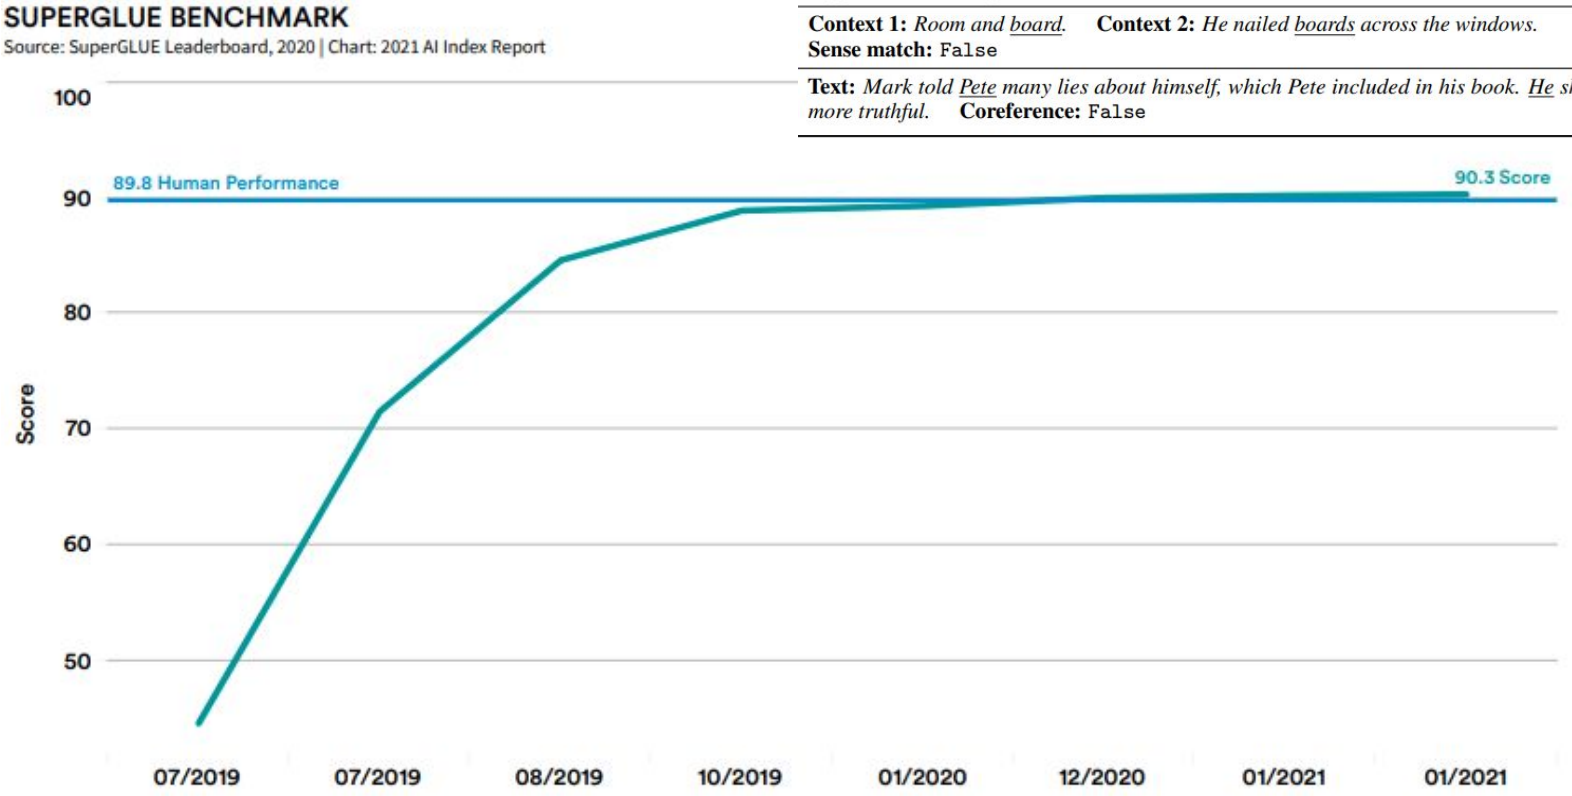
https://aiindex.stanford.edu/wp-content/uploads/2021/03/2021-AI-Index-Report-_Chapter-2.pdf

Consequência: Emprego da IA em Linguagem

Text: *Dana Reeve, the widow of the actor Christopher Reeve, has died of lung cancer at age 44, according to the Christopher Reeve Foundation.*
Hypothesis: *Christopher Reeve had an accident.* **Entailment:** `False`

Context 1: *Room and board.* **Context 2:** *He nailed boards across the windows.*
Sense match: `False`

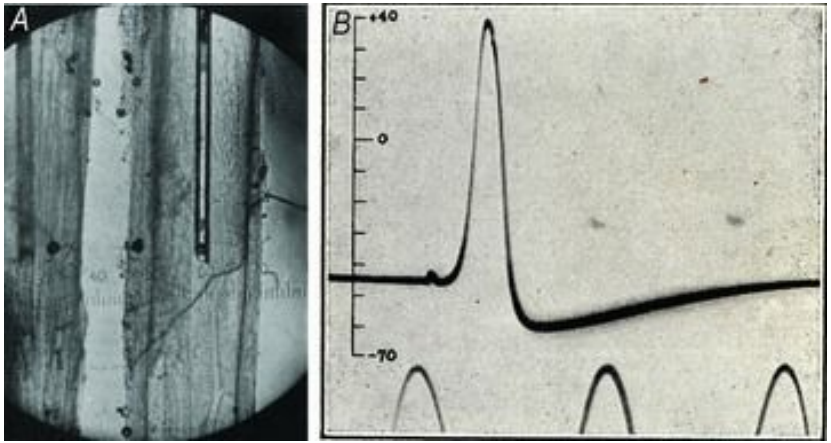
Text: *Mark told Pete many lies about himself, which Pete included in his book. He should have been more truthful.* **Coreference:** `False`



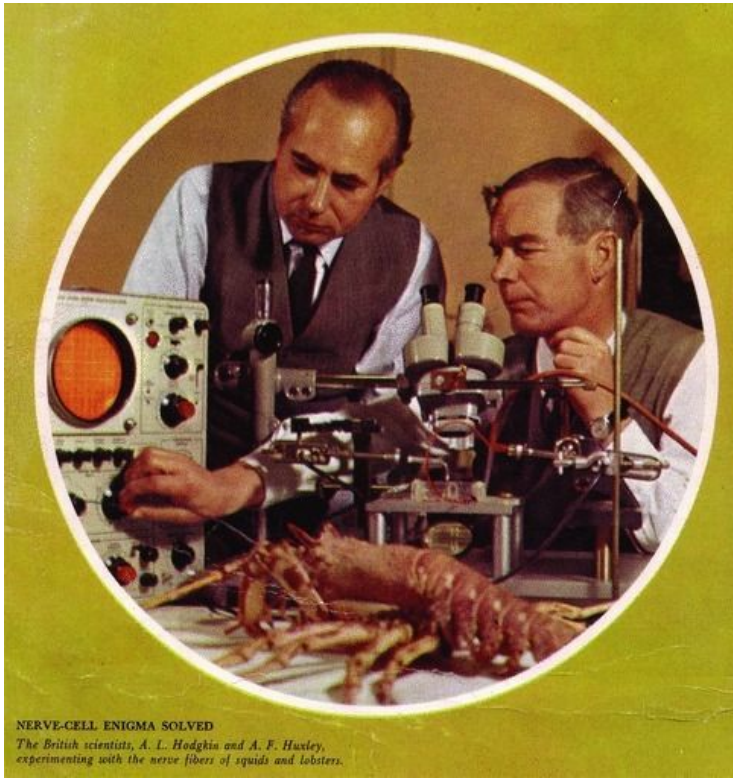
https://aiindex.stanford.edu/wp-content/uploads/2021/03/2021-AI-Index-Report-_Chapter-2.pdf

Inspiração biológica: Neurônio

- 1907: Lapicque iniciou trabalho de descrever o comportamento do neurônio em função da voltagem, capacitância e evolução temporal.
- 1939: Alan Hodgkin e Andrew Huxley aprimoram a modelagem considerando canais iônicos das células.
- 1963: Nobel pela modelagem de Huxley-Hodgkin

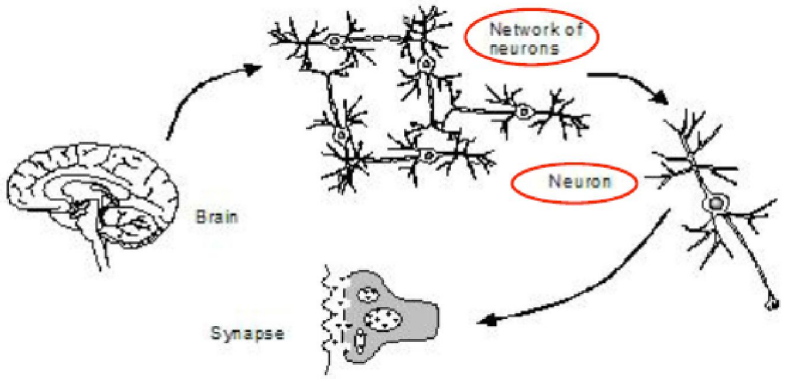


A brief historical perspective: Hodgkin and Huxley. J Physiol. 2012


NERVE-CELL ENIGMA SOLVED
The British scientists, A. L. Hodgkin and A. F. Huxley, experimenting with the nerve fibers of squids and lobsters.

O Sistema Nervoso (SN)

- O sistema nervoso **traz informações** para o organismo sobre o ambiente ao seu redor, através de entradas sensoriais, **processa a informação** de entrada, **compara com experiências anteriores**, e **<u>transforma</u>** essas entradas em ações ou memória.



Neurônio(s)

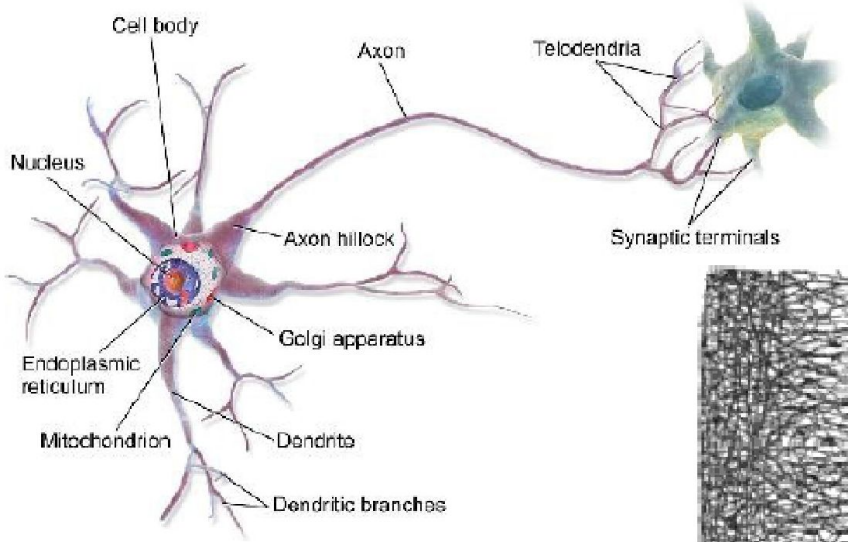


Figure 10-1. Biological neuron[3]

Conhecimento global é resultado de mudanças locais nos neurônios: *sinapses*.

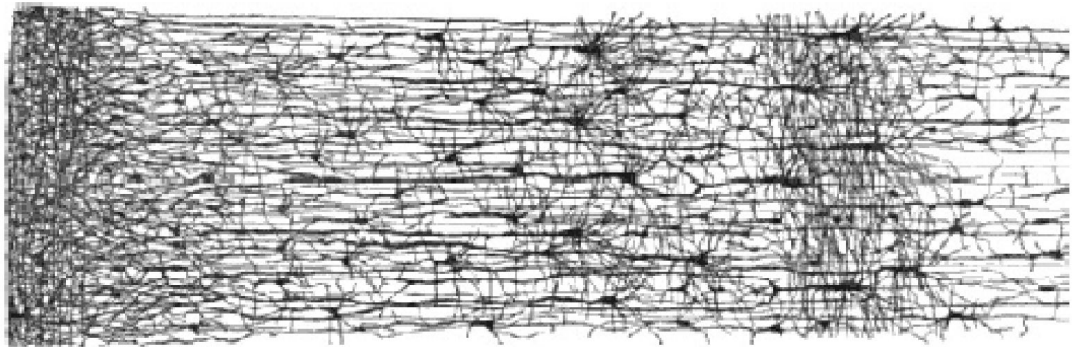


Figure 10-2. Multiple layers in a biological neural network (human cortex)[5]

Comparação entre o Cérebro e o Computador

Table 2. Architecture comparison.

	Brain	Microprocessor
Memory location relative to computing circuits	Embedded	Separated
Parallelism	High	Low
Component predictability	Probabilistic	Deterministic
Component redundancy	High	Low
Fault tolerance	High	Low
Scalability	Very high	Low

Fonte: Naveen Nagarajan. How does the speed of thought compare for brains and digital computers? Current Biology. 2008

Comparação entre o Cérebro e o Computador

Parâmetro	Cérebro	Computador
Material	Orgânico	Semicondutores, metais
Velocidade	Milisegundos	Nanosegundos
Tipo de Processamento	Massivamente Paralelo	Usualmente Sequencial
Forma de Processamento	Distribuído	centralizado
Armazenamento	Adaptativo	Estático
Elementos de processamento	~10^{11} (neurônios)	~10^{9} (transistores)
Eficiência energética	~10^{-16} J/op./seg.	10^{-6} J/op./seg.
Ligações por elementos de proces.	~10000	~10

Fonte: S. Singh Prediction of Depth Maps using Semi-Supervised Learning. 2020

Conteúdos e Estratégia de Avaliação

Conteúdos da Disciplina

- Redes Neurais Artificiais
- Multilayer Perceptron
- Backpropagation
- Redes de Convolução
- Parametrização
- Redes recorrentes
  - Simples
  - LSTM
  - GRU
- Representação com Autoencoders

Redes Neurais Artificiais

Redes Neurais Artificiais

"**Redes Neurais Artificiais** são dispositivos de computação paralela que consistem de muitos **processadores interconectados**. Esses processadores são simples... Cada processador está ciente apenas dos **sinais que manda** e **recebe** de outros processadores periodicamente"

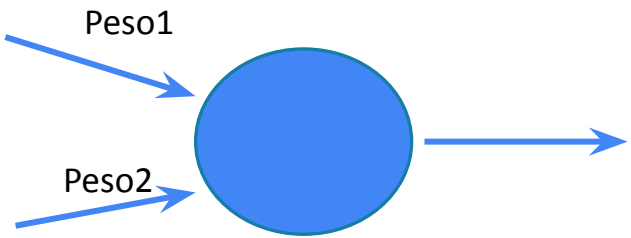
(R. Callan, "The Essence of Neural Networks")

Redes Neurais Artificiais (RNA)

- Técnicas inspirada no funcionamento do cérebro.
- Processamento da informação ocorre nos neurônios.
- Neurônios recebem e enviam estímulos do/para outros neurônios e de/para o ambiente.
- Neurônios podem ser conectados formando redes neurais.
- Informação é transmitida através de "sinapses".
- A eficiência de uma sinapse é representada por um peso, que corresponde a informação armazenada no neurônio.
- Conhecimento é adquirido através de aprendizagem.
    - Ou seja: **adaptação dos pesos** das sinapses de acordo com a informação do ambiente.
- Pode ser vista como estratégia de aproximação de funções por regressão não linear.

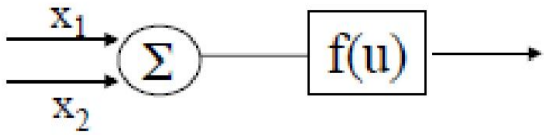
Redes Neurais: Padrão Genérico

- Caracterizadas por 3 elementos:
  - Conjunto de neurônios artificiais
  - Um padrão de conexão entre os neurônios: arquitetura ou estrutura da rede
  - Método que determina o valor dos pesos: algoritmo de treinamento ou aprendizagem



Primeiro Modelo

- “A Logical Calculus of Ideas Immanent in Nervous Activity” - McCulloch-Pitts (1943)
- Segundo eles, com um modelo simplificado é possível construir uma rede artificial de neurônios que computa qualquer proposição lógica.
- Neurônio de 2 estados
  - Comportamento de um neurônio é um processo binário
- Cada neurônio tem um limiar fixo l
  - função de ativação
  - Será ativo quando mais que um certo número de entradas estiverem ativos



$$l = 1$$

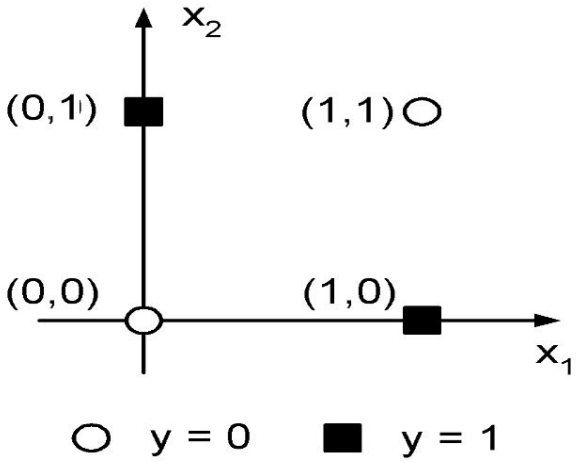
$$l = 2$$

Redes Perceptron

Redes Perceptron

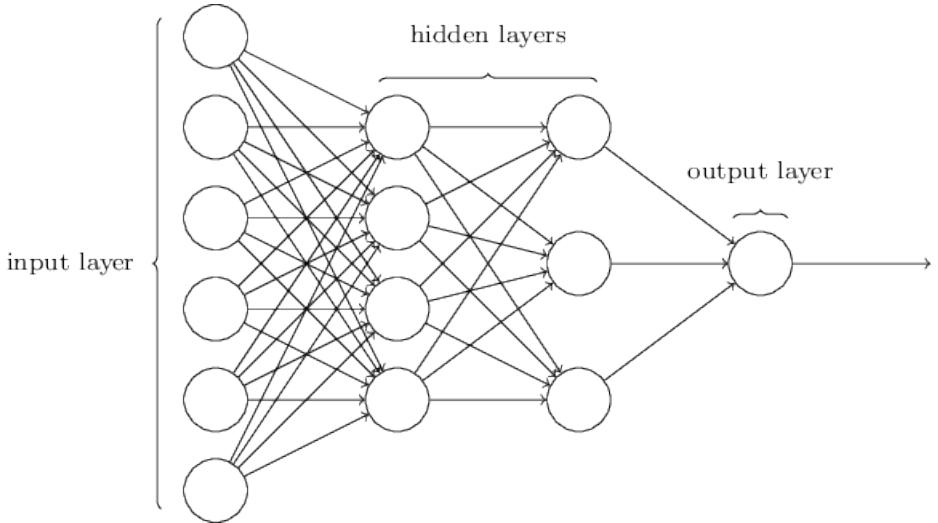
- Limitação crônica! (AI Winter)
  - Problema do ou exclusivo
  - Problema de separação linear
- Superação: Teorema da aproximação universal (1989)

x_1	x_2	x_1 XOR x_2
0	0	0
0	1	1
1	0	1
1	1	0



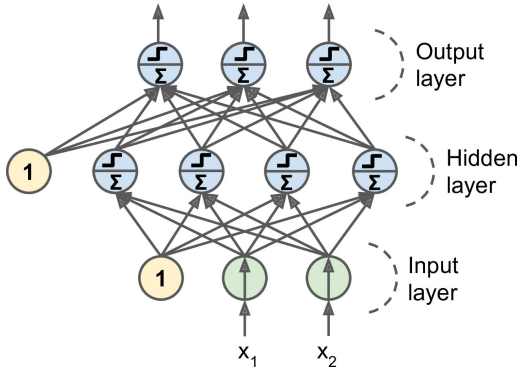
Multilayer Perceptron

- 1957 - Rosenblatt (Perceptron = “princípio do aprendizado”)
- Imagine se a saída de uma camada de neurônios (perceptrons) forem a entrada de outra camada...
- Assim, o perceptron da segunda camada pode tomar decisões ainda mais complexas e abstratas;



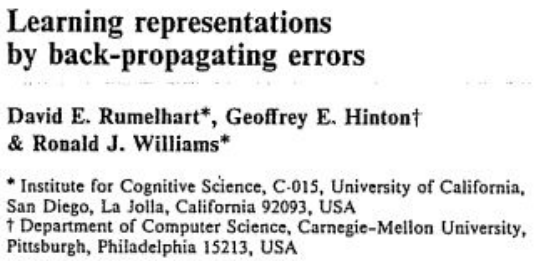
Multilayer Perceptron

- Quando aplicamos várias camadas, saímos de Redes Neurais Artificiais, e nos localizamos nos tão famosos Deep Neural Networks.
- O termo “oculto” nessas redes pode parecer um pouco misterioso, mas na prática diz que não é a entrada, nem a saída.
- Temos ainda os termos **lower layer** e **upper layers**.



Backpropagation

BackPropagation



Learning representations by back-propagating errors

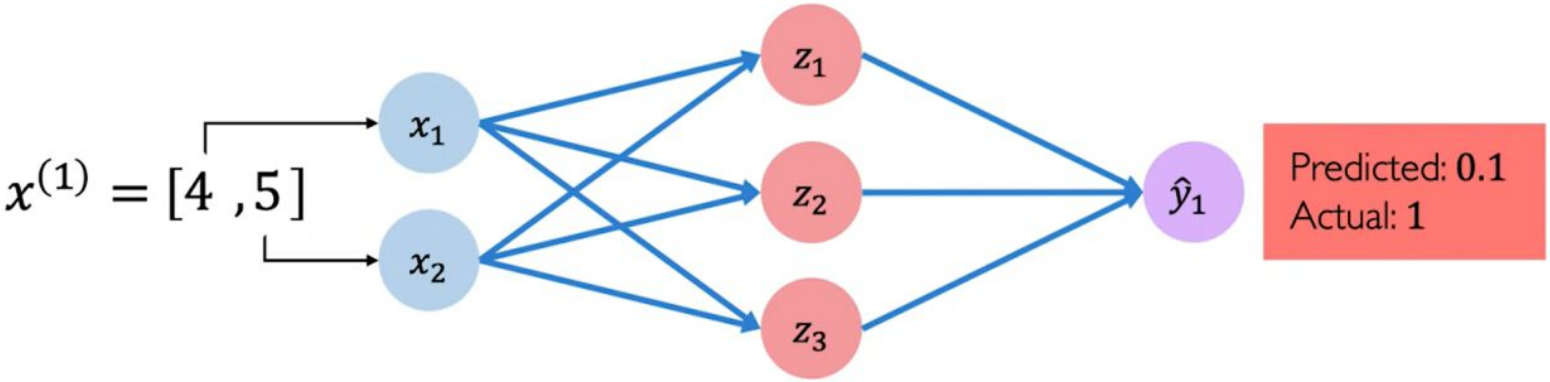
David E. Rumelhart*, Geoffrey E. Hinton† & Ronald J. Williams*

* Institute for Cognitive Science, C-015, University of California, San Diego, La Jolla, California 92093, USA
† Department of Computer Science, Carnegie-Mellon University, Pittsburgh, Philadelphia 15213, USA

- Criado em 1970, mas realmente valorizado em 1986, no paper famoso de Rumelhart, Geoffrey Hinton e Ronald Williams
- Backpropagation versa sobre entender como iremos mudar os pesos, seguindo as mudanças na função custo.
- Logo, requisitos importantes para função de custo em redes neurais:
  - A função custo deve ser obtida a partir de uma média na análise de perda individual.
  - A função custo deve ser escrita como uma função de saída da rede neural
- Uma das mais populares idéias em IA
  - >25 mil citações!

Backpropagation - Quantificando a perda

Precisamos mensurar o custo de uma predição incorreta

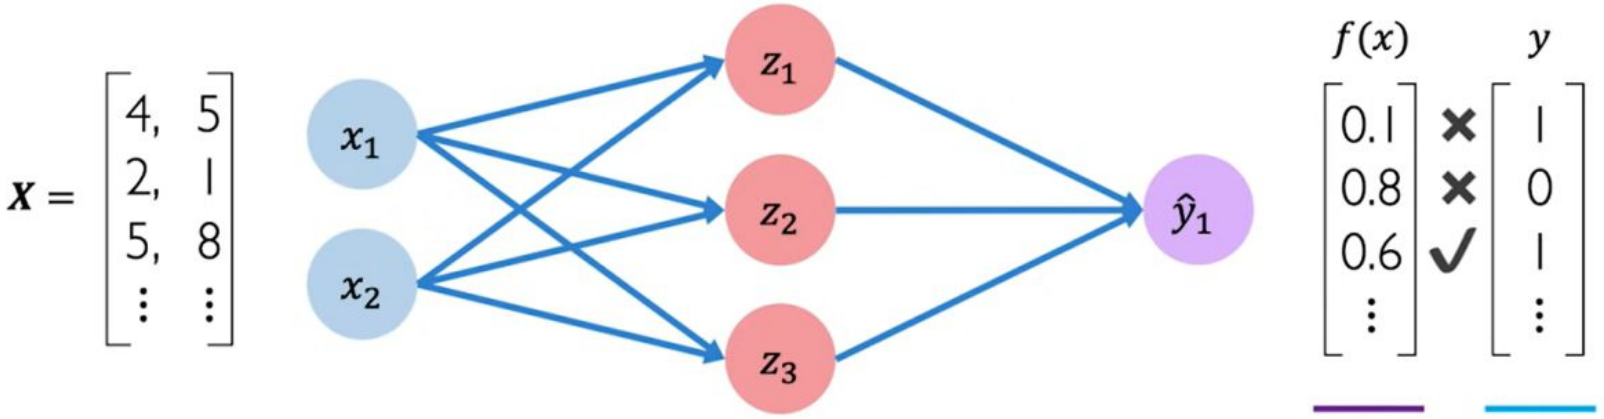


$$\mathcal{L}\left(f\left(x^{(i)}; \boldsymbol{W}\right), y^{(i)}\right)$$

Predicted Actual

Backpropagation - Quantificando a perda

- Uma função de custo mensura as perdas em toda a coleção!



Also known as:
- Objective function
- Cost function
- Empirical Risk

$$J(W) = \frac{1}{n}\sum_{i=1}^{n} \mathcal{L}\left(f\left(x^{(i)}; W\right), y^{(i)}\right)$$

Predicted Actual

Parametrização

Parametrização

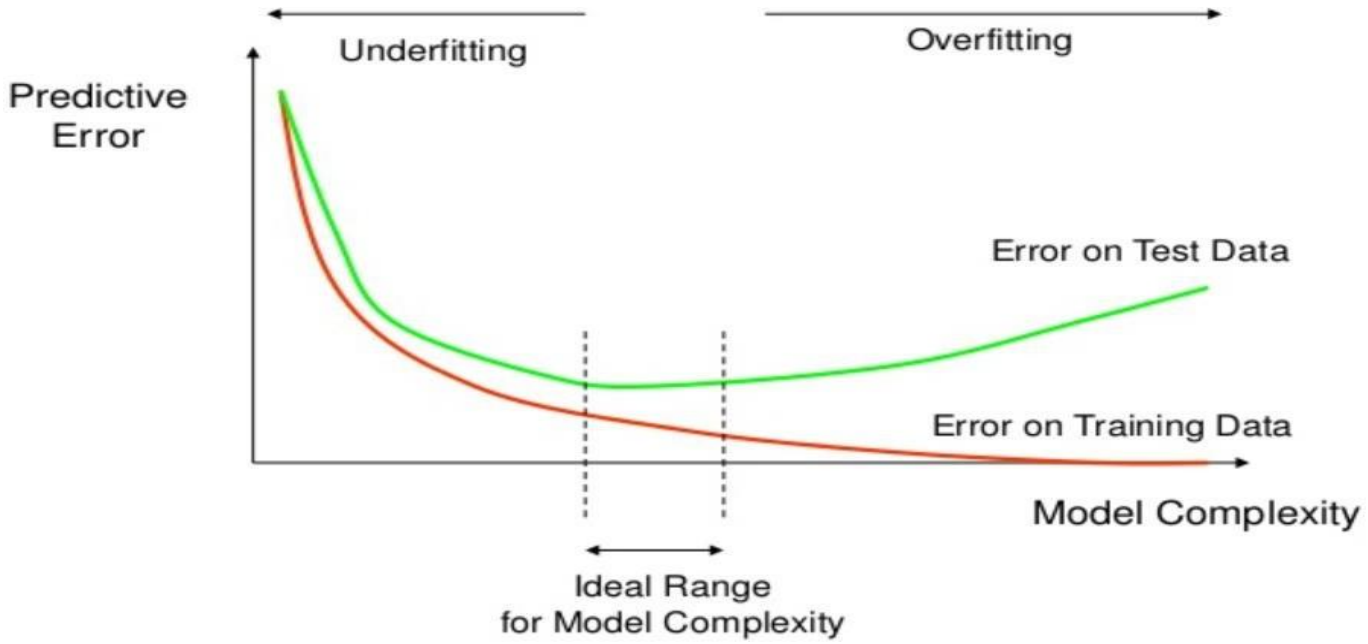
- Lidando com (Hiper)parâmetros!
- Problemas…
  - Potenciais soluções/parametrizações
  - Vanish/exploding gradients
  - Treino lento…
- Interpretação e Correção de Resultados (Ciclo Vicioso de ML)
- Depurando código

Parametrização

- Quantas camadas?
- Quantos neurônios?
- Quantas épocas (epochs)?
- Quantos batches?
- Qual a taxa de aprendizado?
- Qual Função de ativação?
- Qual arquitetura?
- Qual Inicialização de pesos?
- Qual a regularização? Dropout?

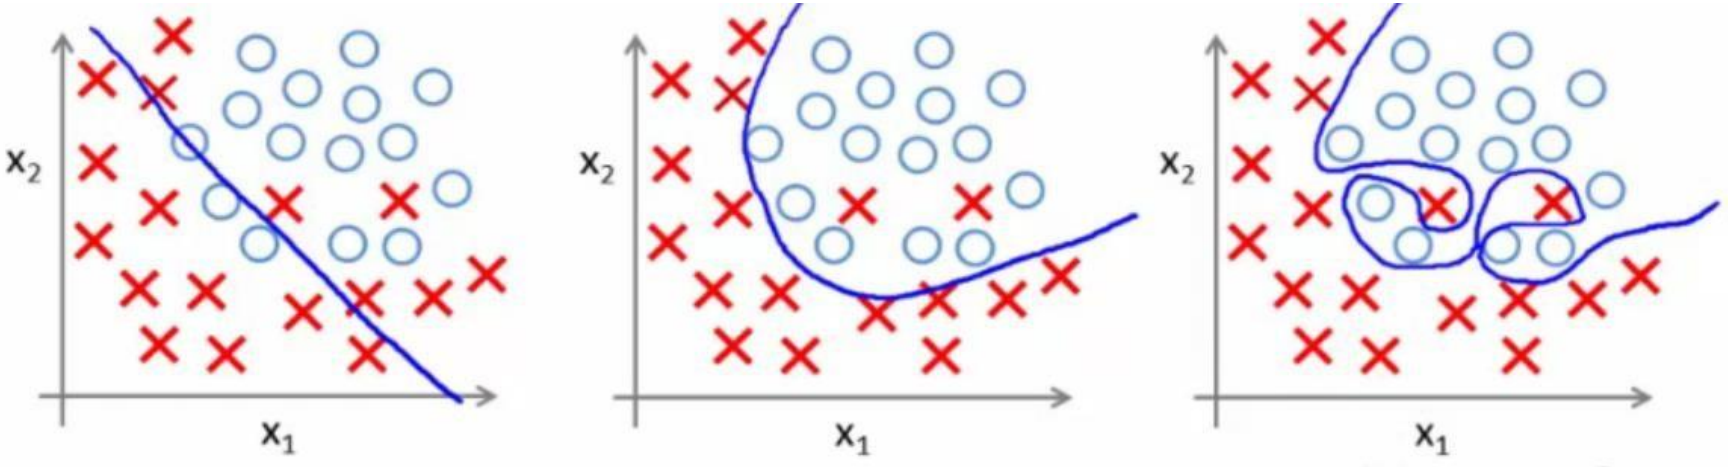
Parametrização

- Em resumo: como tentar chegar no modelo “ideal”?



Parametrização

- Em resumo: como tentar chegar no modelo “ideal”?

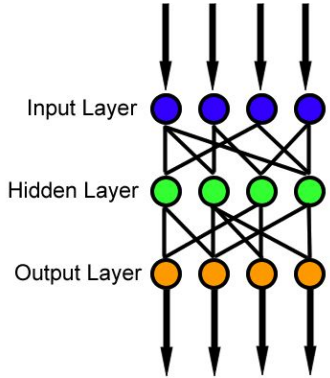


Redes Recorrentes

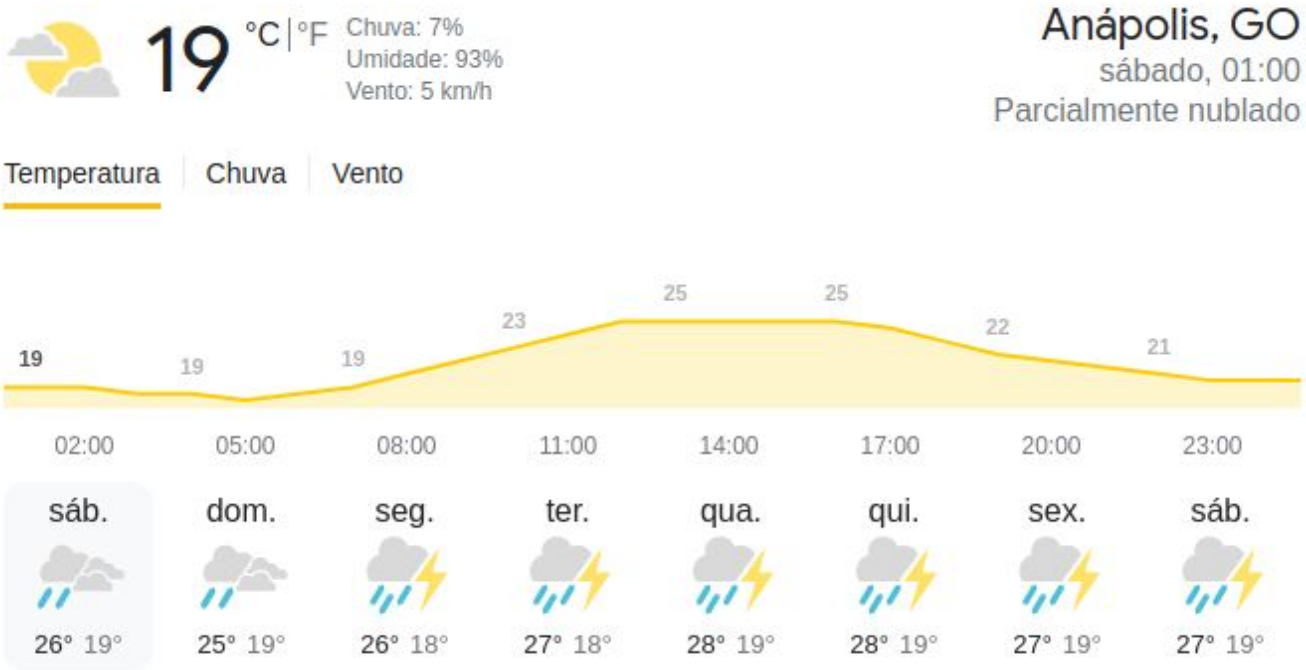
Por que redes neurais recorrentes?

- Até o momento:
  - Tratamos uma única entrada (ex. um conjunto de features, uma imagem, etc.)
  - Tratamos redes neurais diretas (feedforward networks)
- só que…
  - Muitas entradas são **sequenciais** ou precisam receber sinais dependentes do tempo, ex.:
    - Dados de sensores (velocidade, temperatura, consumo energético, etc)
    - Texto (texto=sequência de palavras)
    - Fala/música (reconhecimento de fala, classificação de música)
    - Vídeos (detecção de objetos/faces)
  - “Snapshots” podem não ser informativos (ex: trajetória de uma bola)
- **Contexto temporal** é importante!

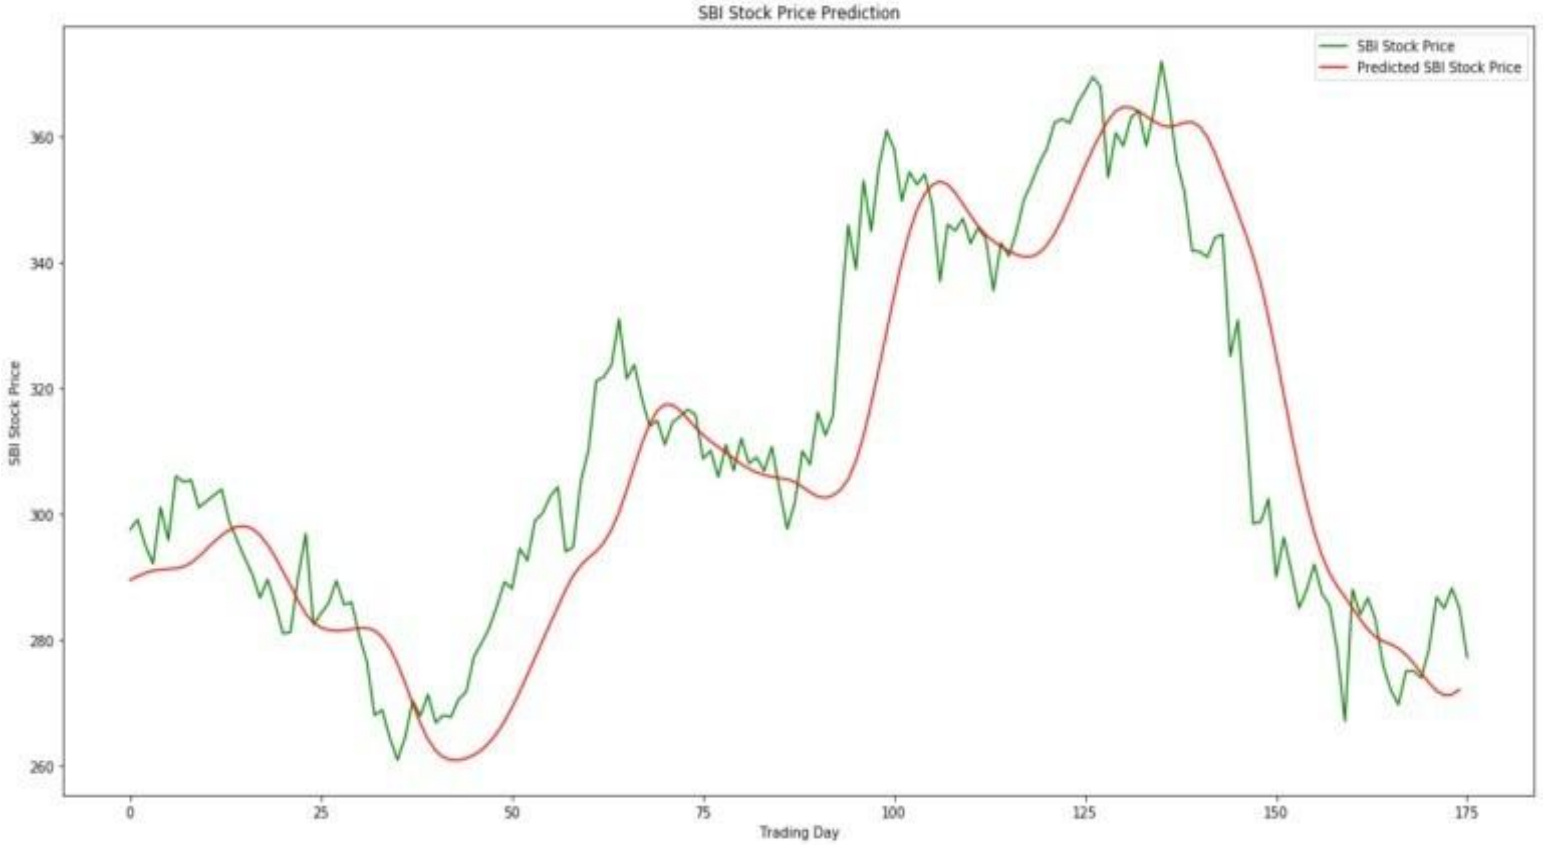
Rede Neural Direta (feedforward)



Por que redes neurais recorrentes?



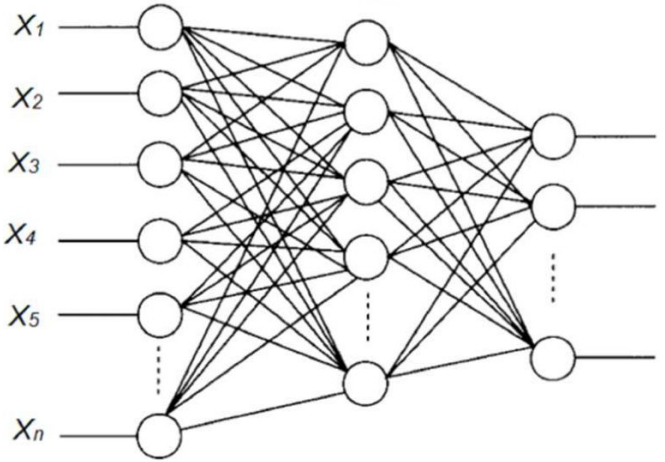
Por que redes neurais recorrentes?



Por que redes neurais recorrentes?

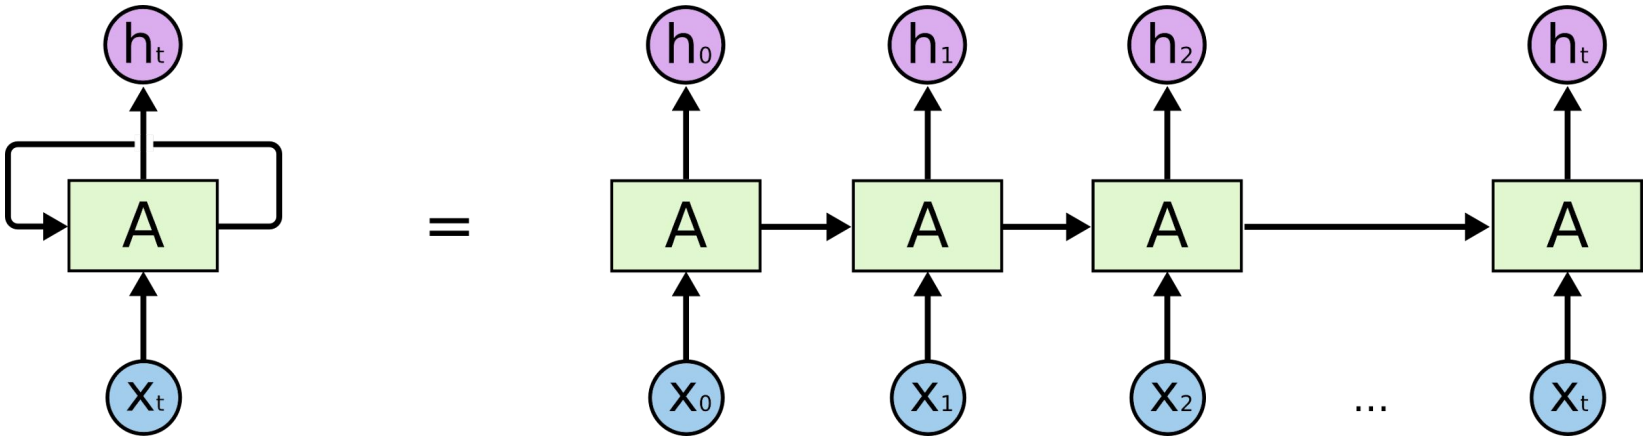
"*Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam eget ligula eu lectus lobortis condimentum. Aliquam nonummy auctor massa. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Nulla at risus. Quisque purus magna, auctor et, sagittis ac, posuere eu, lectus. Nam mattis, felis ut adipiscing.*"

?



Redes Recorrentes...

- Redes recorrentes podem ser pensadas como múltiplas cópias da mesma rede.
- A cada passada, a versão anterior passa uma “mensagem” para próxima rede.

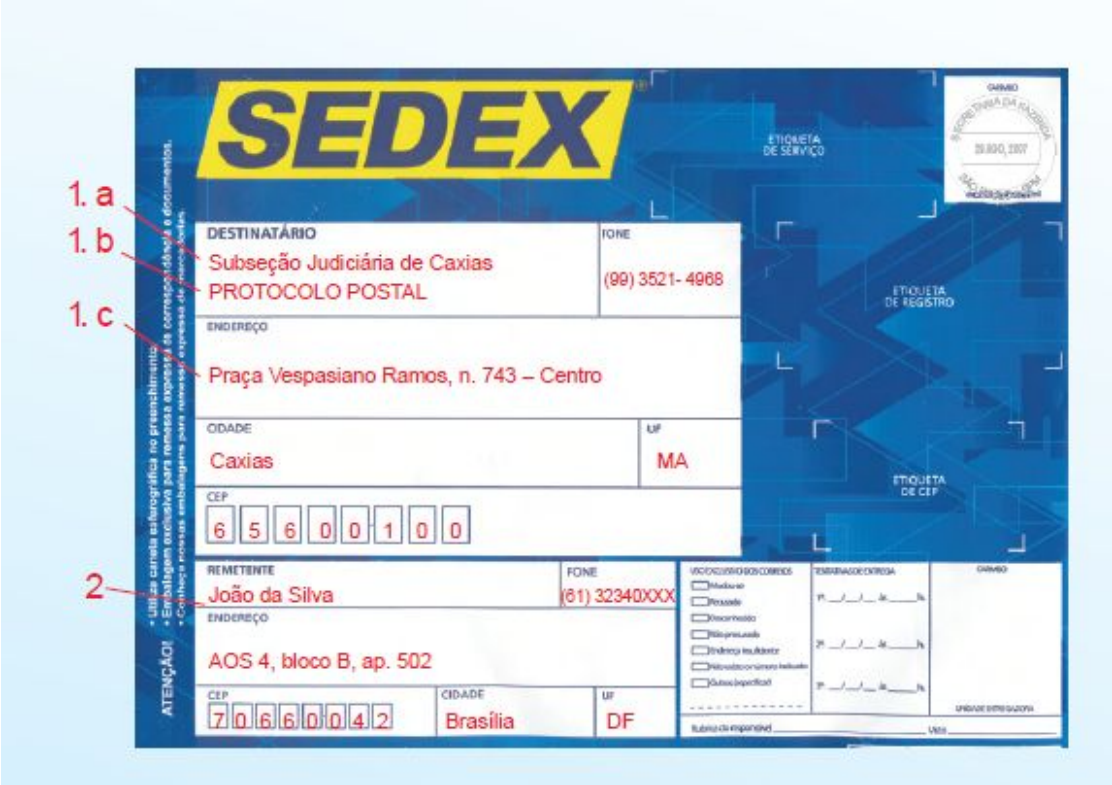


Redes de Convolução

Redes de Convolução: Contexto



Redes de Convolução: Contexto



Rede Neural Convolucional

- CNN’s foram inspiradas pela sensibilidade local e orientação seletiva do cérebro.

- Projetaram uma rede neural que implicitamente extraiam características relevantes da entrada.
  - Em uma imagem, o que tem de característica relevante?

- Redes convolucionais são um tipo especial de multi-layer Perceptrons (MLP).

Rede Neural Convolucional

- Problema: Entrada pode ter uma dimensão muito alta. Multi-Layer Perceptron.
- Inspirado pelos experimentos de neurofisiologia [Hubel & Wiesel 1962], CNNs são um tipo especial de redes neurais que usam o conceito de campo receptivo local.
    - Nos estudos do córtex visual, descobriu-se que **cada neurônio responde apenas a uma região específica da retina**, e não a toda a imagem. Essa região é chamada de **campo receptivo** (*receptive field*).

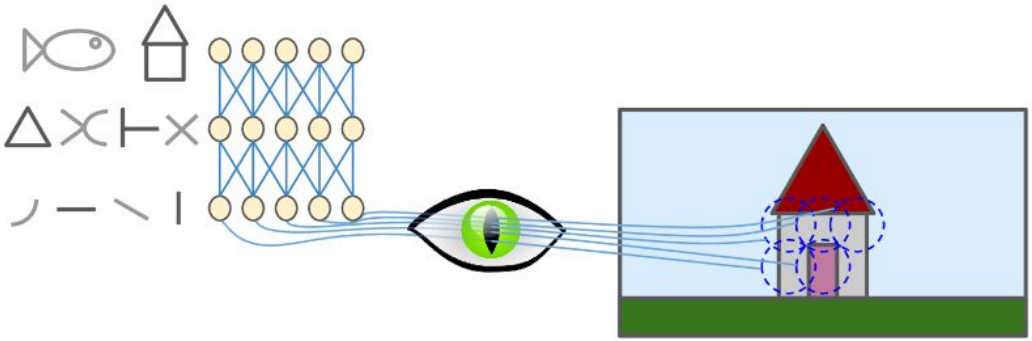
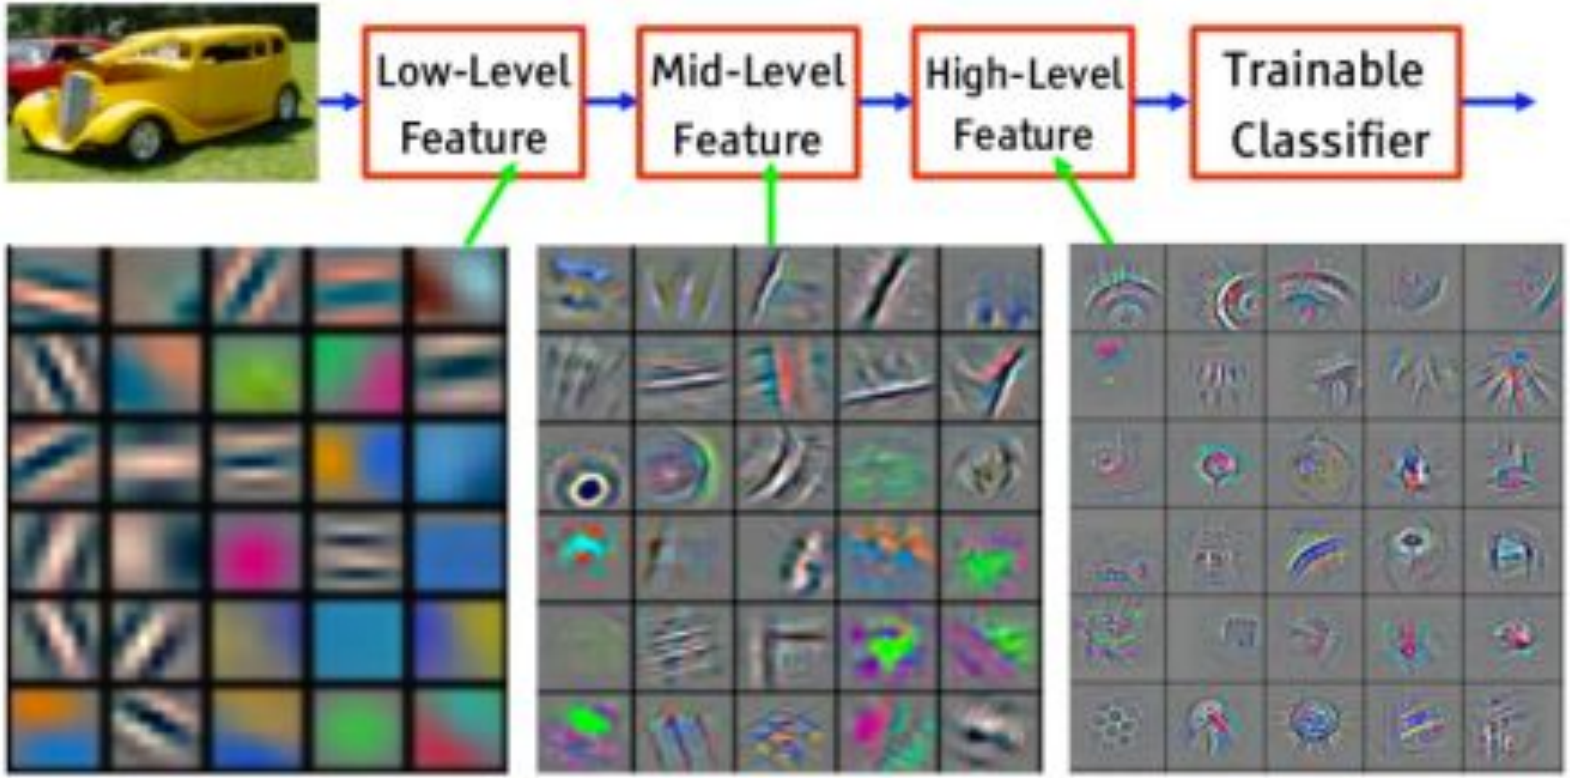
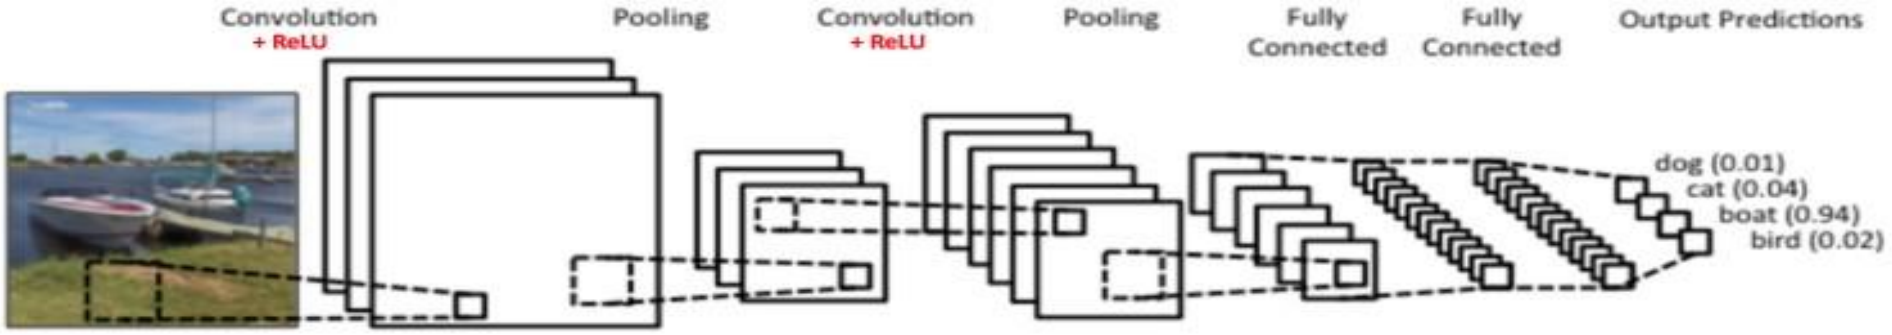


Figure 3-1. Local receptive fields in the visual cortex

Rede Neural Convolucional



Rede Neural Convolucional



Autoencoders

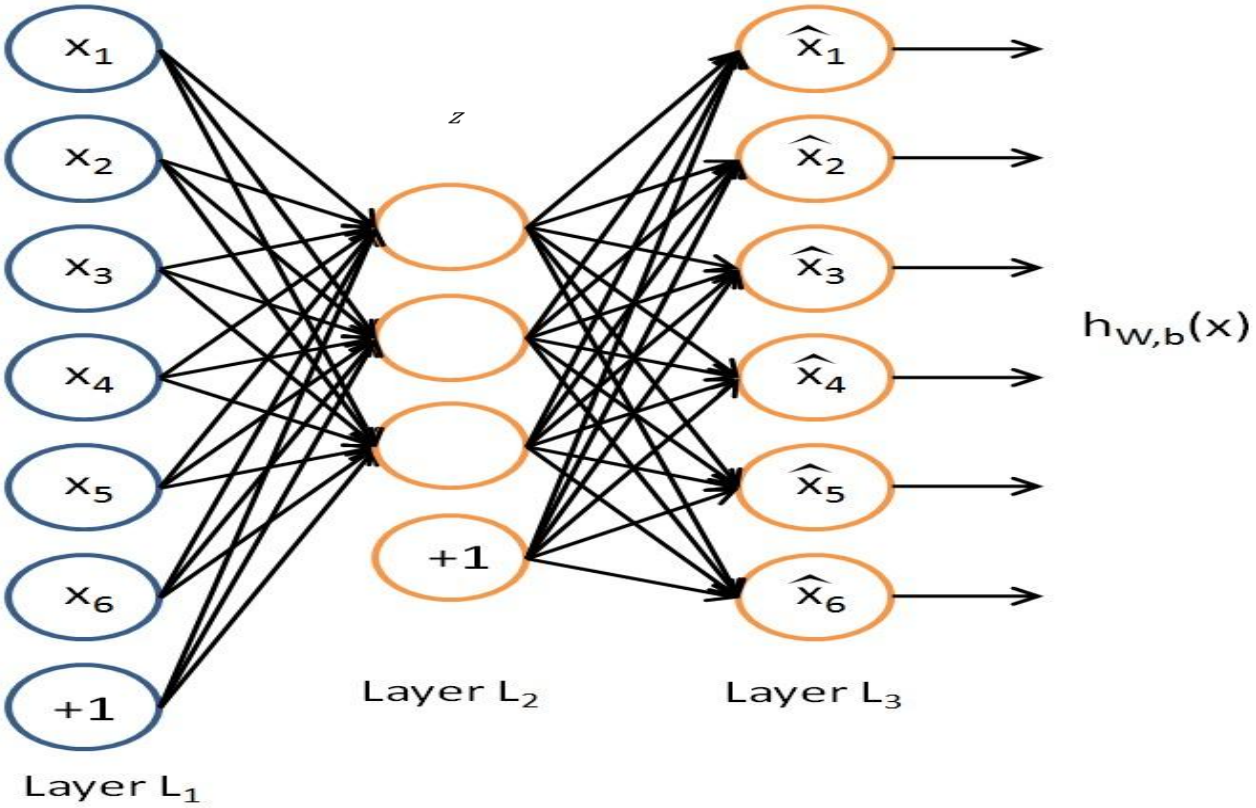
Redes autocodificadoras (*autoencoders*)

- Problema:
  - Maldição da dimensionalidade!
    - Atributos em demasia…
    - Muitos atributos irrelevantes…
    - Atributos similares…
    - Modelo focando em detalhes irrelevantes…

Redes autocodificadoras (*autoencoders*)

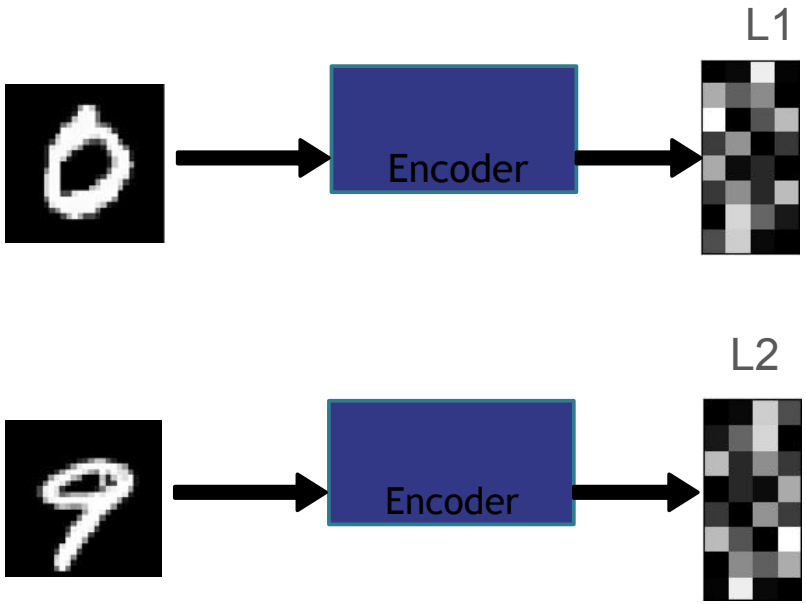
- Podem aprender a estrutura do conjunto de dados de forma não supervisionada
- Aprendizado de representações mais concisas
- Atributos identificados são úteis para uso posterior em aprendizagem supervisionada ou geração de dados (métodos generativos).

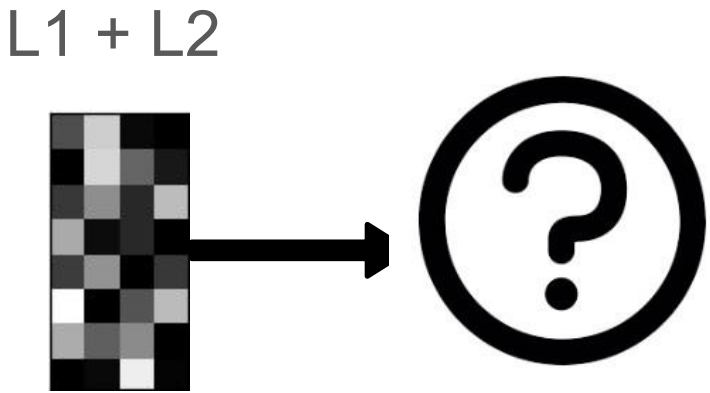
Autoencoder Tradicional



Exemplo de Aplicação: Geração

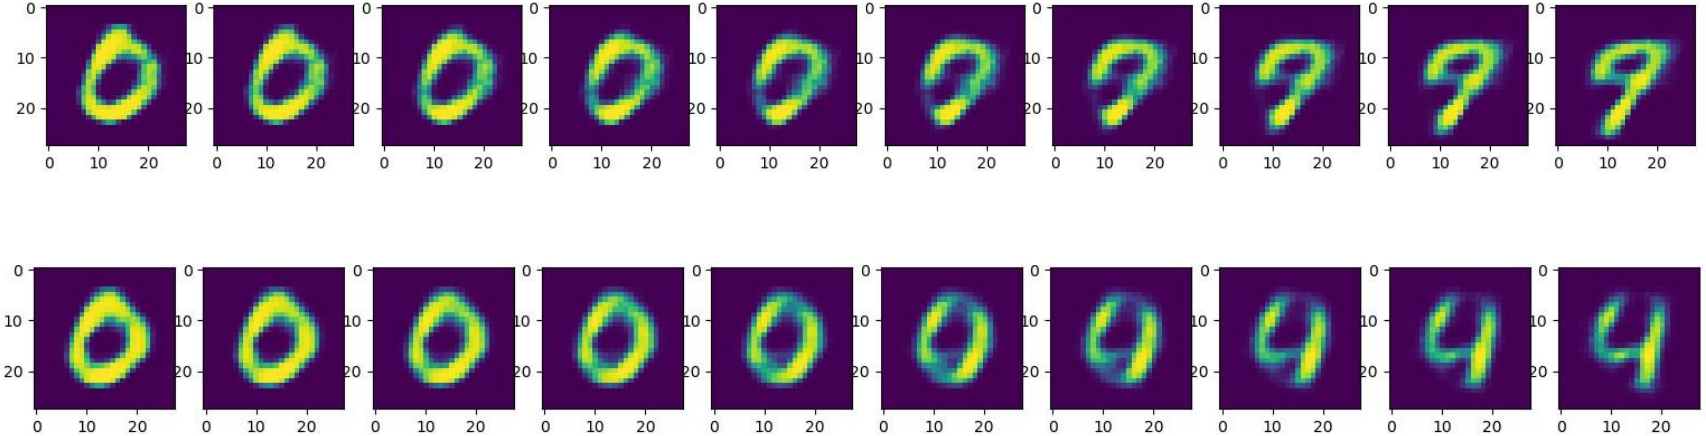
Dado que os padrões fundamentais de um dado são aprendidos com autoencoder, é possível gerar novos dados sintéticos!





Exemplo de Aplicação: Geração

Dado que os padrões fundamentais de um dado são aprendidos com autoencoder, é possível gerar novos dados sintéticos!



https://blog.keras.io/building-autoencoders-in-keras.html

Exemplo de Aplicação: Geração

Dado que os padrões fundamentais de um dado são aprendidos com autoencoder, é possível gerar novos dados sintéticos!

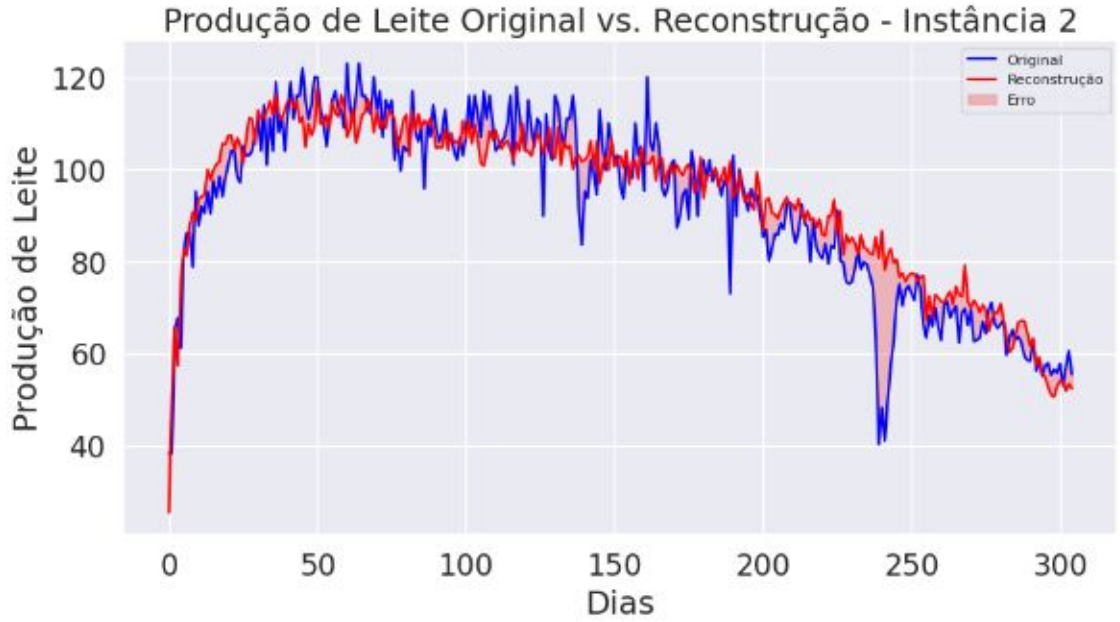


Figure 8.10 A continuous space of faces generated by Tom White using VAEs

Fonte: cap. 8, Deep Learning with Python de François Chollet

Exemplo de Aplicação: Curvas de lactação

Objetivo: aplicar autoencoders para reconstruir a curva de lactação utilizando apenas 10 pontos da curva original.



(TCC do aluno Caio Frauzino)

Estratégia de Avaliação

- Avaliação continuada:
  - Participação e entrega de exercícios - 20%
- Trabalho Final (15/10):
  - Apresentação, Código e Relatório - 80%

Exercícios

INSTITUTO FEDERAL
Goiás

Responda às perguntas abaixo (criticando o output do ChatGPT):

1. Ignorando conceitos de redes neurais, quais características devem estar presentes em um modelo de "*deep learning*"? Detalhe explicando o conceito de regularização.
2. Porque as soluções de deep learning são predominantemente implementadas usando redes neurais?
3. Seja um problema de classificação onde são utilizadas, de forma efetiva, as estratégias de aprendizado de máquina SVM e Árvore de Decisão. Quais cenários possíveis em que o emprego de uma estratégia de deep learning para esse problema é desvantajosa em relação às estratégias de aprendizado de máquina? E vantajosa? Explique.
4. Ignorando conceitos de redes neurais, qual a relação entre *deep learning* e as outras técnicas de aprendizado de máquina?
    a. … o que tem de similar?
    b. … e o que tem de diferente?
5. Sem utilizar conceitos de redes neurais, explique como funcionam os autoencoders.
6. Suponha que uma empresa o contratou para o desenvolvimento da melhor solução possível de deep learning nos três projetos abaixo. Descreva, de forma geral e simplificada, os passos suficientes e necessários para execução de cada projeto.
    a. Análise do sentimento dos usuários do twitter em relação ao Vila Nova F.C. em mensagens do twitter.
    b. Classificação de imagens entre imagens que possuem fissuras em concreto e imagens que não possuem fissuras.
    c. Predição do fechamento diário do preço de ações da companhia Americanas (AMER3).

Referências

[1] Aurélien Géron. Neural networks and deep learning (cap. 1) https://www.oreilly.com/library/view/neural-networks-and/9781492037354/ch01.html

[2] NIELSEN, M. A. Neural Networks and Deep Learning. Determination Press, 2015. [Online]. Disponível em <http://neuralnetworksanddeeplearning.com/>

[3] GOODFELLOW, Y. BENGIO, A. COURVILLE. Deep Learning. MIT Press, 2017.

[4] François Chollet. Deep Learning with Python. Manning publications. 2019