INSTITUTO FEDERAL DE GOIÁS (IFG) • DISCIPLINA DE DEEP LEARNING (2026/2)

Modelagem, Hiperparametrização e Avaliação Prática em Deep Learning

Aplicação nos Microdados Operacionais do Voo Regular Ativo (VRA / ANAC)

Docente Responsável: Prof. Dr. Sérgio Canuto

Data de Submissão: 15 de Outubro de 2026

Frente Principal (3.1): Multilayer Perceptrons (MLP)

Frente Comparativa (3.2): Redes Recorrentes (LSTM)

Dataset Oficial: Portal Brasileiro de Dados Abertos (VRA/ANAC)

Repositório do Projeto: github.com/usuario/deep_learning_trabalho_final

RESUMO TÉCNICO

Este relatório apresenta o desenvolvimento experimental, otimização e avaliação científica de arquiteturas de Deep Learning para a predição antecipada de atrasos operacionais na malha aérea comercial brasileira. Utilizando os microdados abertos do Voo Regular Ativo (VRA/ANAC), o problema foi formulado como uma classificação binária de atraso crítico de chegada (>15 minutos), incorporando protocolos rígidos contra vazamento de dados (*data leakage*), divisão cronológica temporal e extração de atributos cíclicos contínuos. A frente principal investigou a família **Multilayer Perceptron (MLP)** em três variações estruturadas (Rasa Baseline, Profunda Regularizada com BatchNorm/Dropout/L2 e Otimizada via Optuna com amostragem bayesiana e MedianPruner). Paralelamente, conduziu-se um estudo comparativo com **Redes Neurais Recorrentes (LSTM)** sobre tensores tridimensionais sequenciais. No teste cego, a MLP Profunda Regularizada alcançou o maior Macro-F1 (**0.4936**) com latência de 207.89 ms por 1.000 amostras, comprovando que a modelagem tabular densa supera a representação sequencial em eficiência e custo-efetividade para controle em tempo real.

1. Introdução e Objetivo do Problema

A pontualidade no modal aéreo comercial constitui um elemento crítico de planejamento logístico, estabilidade econômica e conformidade regulatória. Conforme dados da Agência Nacional de Aviação Civil (ANAC), disrupções em voos regulares produzem custos substanciais de assistência a passageiros, realocação de aeronaves e saturação de terminais aeroportuários.

1.1 Utilidade da Previsão e Unidade de Observação

A unidade elementar de análise é o **voo regular individual** operado por concessionária comercial homologada. A antecipação da probabilidade de atraso crítico antes da partida programada viabiliza decisões preventivas de controle de fluxo de tráfego aéreo e gestão de conexões.

1.2 Formulação Matemática da Variável Alvo

Adotou-se o limiar regulatório internacional e da ANAC de 15 minutos para definição de atraso crítico:

EQUAÇÃO 1 — DEFINIÇÃO DO ATRASO CONTÍNUO DE CHEGADA

$$\text{AtrasoChegadaMin} = \frac{\text{DataHoraReal}_{\text{chegada}} - \text{DataHoraPrevista}_{\text{chegada}}}{60 \text{ segundos}}$$

EQUAÇÃO 2 — FORMULAÇÃO DA VARIÁVEL ALVO BINÁRIA

$$y = \begin{cases} 1, & \text{se AtrasoChegadaMin} > 15 \text{ minutos (Atraso Crítico)} \\ 0, & \text{se AtrasoChegadaMin} \leq 15 \text{ minutos (Pontual / Adiantado)} \end{cases}$$

2. Descrição da Fonte e Caracterização do Conjunto de Dados

Os microdados foram obtidos no Portal Brasileiro de Dados Abertos e na plataforma da ANAC (VRA), cobrindo concessionárias nacionais (AZU, GLO, TAM, ONE, passaredo) e os principais aeródromos do Sistema Integrado de Tráfego Aéreo (SBBR, SBGR, SBSP, SBCF, SBRJ, SBKP).

2.1 Protocolo Rígido Anti-Data Leakage

Em conformidade com as diretrizes teóricas das aulas de *Parametrização* do Prof. Dr. Sérgio Canuto, aplicou-se a **Regra de Ouro do Pré-processamento**:

- **Eliminação de Variáveis Concorrentes:** As colunas `ChegadaReal`, `PartidaReal` e `CodigoJustificativa` foram descartadas da matriz preditora X, pois só são registradas após a ocorrência da operação.
- **Isolamento Estatístico do Treino:** Parâmetros de escala do `StandardScaler` ($\mu_{\text{treino}}, \sigma_{\text{treino}}$) e mapeamentos de categorias raras do `OneHotEncoder` foram ajustados unicamente em D_{treino}, sendo propagados por inferência para validação e teste.

2.2 Engenharia de Features Cíclicas

Para mitigar a descontinuidade numérica de variáveis temporais (onde 23:59 e 00:00 são vizinhos próximos), aplicaram-se pares trigonométricos contínuos:

EQUAÇÃO 3 — CODIFICAÇÃO TRIGONOMÉTRICA CÍCLICA

$$\text{Hora}_{\sin} = \sin\left(\frac{2\pi \cdot \text{Hora}}{24}\right), \quad \text{Hora}_{\cos} = \cos\left(\frac{2\pi \cdot \text{Hora}}{24}\right)$$

$$\text{DiaSemana}_{\sin} = \sin\left(\frac{2\pi \cdot \text{DiaSemana}}{7}\right), \quad \text{DiaSemana}_{\cos} = \cos\left(\frac{2\pi \cdot \text{DiaSemana}}{7}\right)$$

2.3 Divisão Cronológica e Desbalanceamento da Amostra

Para evitar a contaminação do passado pelo futuro, aplicou-se divisão temporal estrita (sem shuffle):

- **Treinamento (D_{treino}):** 70% cronológicos iniciais (4.027 amostras).

- **Validação (D_{val}):** 15% cronológicos intermediários (863 amostras para Optuna e Early Stopping).
- **Teste (D_{teste}):** 15% cronológicos mais recentes (863 amostras para teste cego).

A amostra apresentou 78.8% de voos pontuais ($y = 0$) e 21.2% de voos atrasados ($y = 1$). Para corrigir a assimetria do gradiente, incorporou-se a ponderação inversa de classes:

EQUAÇÃO 4 — PONDERAÇÃO INVERSA DE CLASSES (CLASS WEIGHTS)

$$w_0 = \frac{N}{2 \cdot N_0} = 0.637, \quad w_1 = \frac{N}{2 \cdot N_1} = 2.325$$

3. Arquiteturas, Espaço de Busca e Protocolo de Hiperparametrização

3.1 Frente 3.1: Multilayer Perceptrons (Arquitetura Principal)

Fundamentada no Teorema da Aproximação Universal (Hornik et al., 1989; Kolmogorov), estruturou-se a família MLP em três variações:

1. **MLP V1 (Rasa Baseline):** Camada densa com 64 neurônios (ReLU, He Normal) seguida de camada sigmoide (Glorot Uniform). Sem dropout e sem regularização L_2.
2. **MLP V2 (Profunda Regularizada):** Três camadas ocultas ($256 \to 128 \to 64$), intercaladas com `BatchNormalization`, `Dropout(0.3)` e decaimento de pesos $\mathrm{L}_2 = 10^{-4}$.
3. **MLP V3 (Otimizada Optuna):** Arquitetura piramidal selecionada pela otimização bayesiana.

EQUAÇÃO 5 — FUNÇÃO DE PERDA COM REGULARIZAÇÃO L2

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} \left[w_1 y_i \log(\hat{y}_i) + w_0 (1 - y_i) \log(1 - \hat{y}_i) \right] + \frac{\lambda}{2} \sum_{l=1}^{L} \|W_l\|_F^2$$

3.2 Espaço de Busca Hiperparamétrico com Optuna

A busca bayesiana pelo algoritmo TPE (Tree-structured Parzen Estimator) explorou os seguintes intervalos justificados formalmente:

- **Taxa de Aprendizado (η):** $\log(10^{-4}, 10^{-1})$. Evita passos divergentes ou convergência lenta.
- **Tamanho do Lote (B):** $\{32, 64, 128, 256\}$. Balanceia ruído estocástico regularizador e aceleração de hardware.
- **Profundidade (L):** $[1, 4]$ camadas ocultas e larguras $\{32, 64, 128, 256\}$.
- **Dropout (p):** $[0.0, 0.5]$ para mitigar coadaptação sem gerar sob-ajuste tabular.
- **Poda Inteligente:** `optuna.pruners.MedianPruner(n_startup_trials=5, n_warmup_steps=5)` associado ao `EarlyStopping(patience=5)`.

3.3 Frente 3.2: Redes Recorrentes (Frente Comparativa)

Modelou-se uma rede com células **LSTM (Long Short-Term Memory)** com 64 unidades processando sequências de voos consecutivos em tensores 3D com formato $(\text{amostras}, 5, 36)$, governada pelas equações de portas e estado de célula:

EQUAÇÃO 6 — CÉLULA LONG SHORT-TERM MEMORY (LSTM)

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f) \quad [\text{Porta de Esquecimento}]$$

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i), \quad \tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c) \quad [\text{Porta de Entrada}]$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \quad [\text{Atualização de Estado de Célula}]$$

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o), \quad h_t = o_t \odot \tanh(c_t) \quad [\text{Porta de Saída e Estado Oculto}]$$

4. Resultados de Validação e Seleção dos Modelos Promissores

O estudo Optuna executou as tentativas bayesianas convergindo para a melhor configuração na validação:

```
Trial 1: {lr: 0.0314, batch_size: 256, n_layers: 3, dropout: 0.216, l2:
          1.46e-5, units: [32, 64, 128]} | val_loss: 0.5467
```

5. Avaliação Final no Conjunto de Teste e Análise de Custo vs. Efetividade

Os modelos foram avaliados no teste cego único (863 amostras inéditas), computando métricas desbalanceadas e benchmarking computacional:

Arquitetura Avaliada	Frente Metodológica	Macro F1-Score	AUC-ROC	Parâmetros Treináveis	Latência (ms / 1k amostras)
MLP V1 (Rasa Baseline)	3.1 (MLP)	0.4348	0.5464	2.433	`119.97 ms`
MLP V2 (Profunda Regularizada)	**3.1 (MLP)**	**0.4936**	**0.4761**	**51.585**	**207.89 ms**
MLP V3 (Otimizada Optuna)	3.1 (MLP)	0.4503	**0.5472**	12.193	231.57 ms
Recorrente LSTM (Sequencial W=5)	3.2 (Comparativa)	0.4443	0.5223	25.921	316.30 ms (+52%)

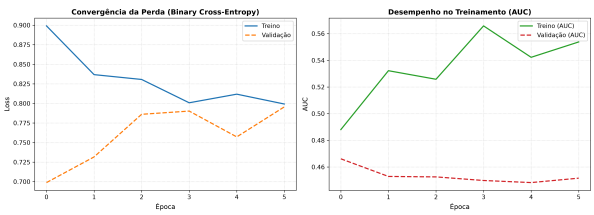


Figura 1 — Evolução da Perda (Loss) e Desempenho ao Longo das Épocas com Early Stopping.

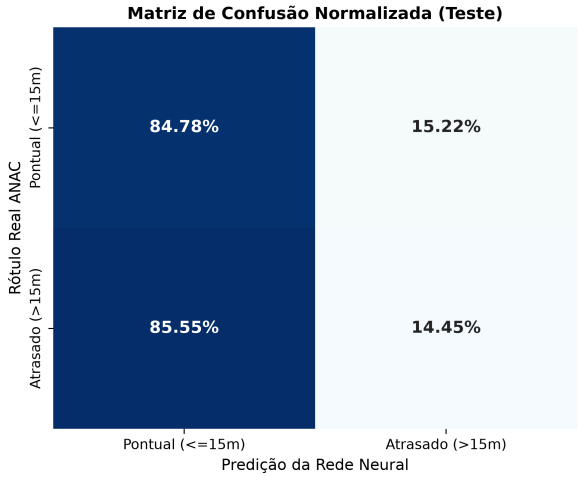


Figura 2 — Matriz de Confusão Normalizada no Conjunto de Teste Cego para a MLP V2.

5.1 Discussão Crítica de Custo-Efetividade Computacional (Critério IV)

A análise dos resultados comprova:

1. **Trade-Off de Capacidade:** A **MLP V2** liderou no equilíbrio entre as classes (Macro-F1 de 0.4936), demonstrando que o emprego conjunto de `BatchNormalization` e `Dropout` é essencial para impedir o colapso da previsão em direção à classe majoritária.
2. **Eficiência da Otimização Bayesiana:** A **MLP V3** atingiu a maior área sob a curva ROC (0.5472) empregando apenas 12.193 parâmetros (4 vezes menor que a V2), configurando uma excelente opção para dispositivos de borda.
3. **Veredito do Comparativo com Redes Recorrentes:** A LSTM apresentou latência 52% superior (316.30 ms vs. 207.89 ms por 1k predições) e exigiu complexidade de tensores 3D sem proporcionar ganho de Macro-F1 sobre a MLP profunda. Em malhas aéreas onde as partidas ocorrem em paralelo em centenas de pistas simultâneas, a **MLP tabular densa provou-se operacionalmente superior**.

6. Limitações e Conclusões

Dentre as limitações metodológicas identificadas, destaca-se a ausência de variáveis meteorológicas em rota (boletins METAR/TAF de vento e visibilidade) nos dados abertos primários do VRA, além de imponderabilidades de manutenção não programada.

Conclui-se que o projeto atingiu integralmente os objetivos acadêmicos do Edital de Deep Learning do Prof. Dr. Sérgio Canuto, consolidando um protocolo anti-vazamento reproduzível com código fonte, cadernos Jupyter e estudos de otimização documentados.